

MTH2302: Estimation

Wisseem Maazoun

École Polytechnique de Montréal

Département de Mathématiques et de génie industriel

Introduction

L'inférence statistique comprend l'estimation et les tests d'hypothèses. L'estimation d'un paramètre consiste à déterminer une statistique qui "reflète" autant que possible la vraie valeur (inconnue) de ce paramètre. Deux méthodes d'estimations sont possibles : l'estimation ponctuelle et l'estimation par intervalle de confiance.

Définition

Soit X une v.a. dont la distribution dépend d'un paramètre θ (ex. $\text{Exp}(\lambda)$, $\text{Poisson}(\lambda)$, etc.), et soit $X_1, X_2, \dots, X_n$ un échantillon **aléatoire** de X . Un estimateur ponctuel de θ est une statistique $\hat{\theta}$ de la forme $\hat{\theta} = h(X_1, \dots, X_n)$, vérifiant certaines propriétés.

Exemples

- Pour estimer une moyenne $\mu = E(X)$ d'une v.a. X , on peut utiliser $\bar{X} = \frac{\sum_{i=1}^n X_i}{n}$.
- Pour estimer une variance $\sigma^2 = V(X)$ d'une v.a. X , on peut utiliser la variance de l'échantillon $S^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n-1}$.

Critère 1 : Le biais

Le biais d'un estimateur $\hat{\theta}$ d'un paramètre θ est défini par

$$\text{Biais}(\hat{\theta}) = E(\hat{\theta}) - \theta.$$

On dit que l'estimateur $\hat{\theta}$ est sans biais (ou non biaisé) pour θ si $\text{Biais}(\hat{\theta}) = 0$, c-à-d si $E(\hat{\theta}) = \theta$.

Exemples

- $E(\bar{X}) = \mu$, donc $\bar{X}$ est un estimateur sans biais de μ .
- $E(\hat{p}) = p$, donc $\hat{p}$ est un estimateur sans biais de p la probabilité de succès.
- $E(S^2) = \sigma^2$, donc S^2 est un estimateur sans biais de σ^2 .

Critère 2 : L'erreur quadratique moyenne (EQM)

On mesure la précision globale d'un estimateur par son erreur quadratique moyenne. Soit $\hat{\theta}$ un estimateur d'un paramètre θ . On définit l'erreur quadratique moyenne de $\hat{\theta}$ par

$$EQM(\hat{\theta}) = E(\hat{\theta} - \theta)^2.$$

On a toujours $EQM(\hat{\theta}) = V(\hat{\theta}) + [Biais(\hat{\theta})]^2$.

Lorsque $\hat{\theta}$ est **sans biais** pour θ , on a

$Biais(\hat{\theta}) = 0$ et $EQM(\hat{\theta}) = V(\hat{\theta})$.

Le critère de l'erreur quadratique moyenne permet de comparer les estimateurs d'un même paramètre. Ainsi, si $\hat{\theta}_1$ et $\hat{\theta}_2$ sont deux estimateurs d'un paramètre θ , le plus efficace des deux est celui ayant la plus petite erreur quadratique moyenne.

$\hat{\theta}_1$ est plus efficace que $\hat{\theta}_2$ si $EQM(\hat{\theta}_1) < EQM(\hat{\theta}_2)$.

Exemple

Soit $X_1, X_2, \dots, X_5$ un échantillon aléatoire d'une v.a. X telle que $E(X) = \mu$ et $V(X) = \sigma^2$. Pour estimer μ , on considère

$$\hat{\mu}_1 = \frac{X_1 + \dots + X_5}{5} \text{ et } \hat{\mu}_2 = \frac{2X_1 - X_2 + X_4}{2}.$$

- ❶ $\hat{\mu}_1$ et $\hat{\mu}_2$ sont-ils sans biais ?
- ❷ Quel est le meilleur des deux ? Justifiez.

Critère 3 : La convergence

Un estimateur $\hat{\theta}_n$ de θ , calculé sur un échantillon de taille n est dit convergent si lorsque $n \rightarrow \infty$, la probabilité que $\hat{\theta}_n$ soit proche de θ devient grande.

$$\forall \epsilon > 0, \lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| < \epsilon) = 1.$$

Une condition suffisante pour la convergence de $\hat{\theta}_n$ est que son erreur quadratique moyenne tende vers zéro lorsque $n \rightarrow \infty$.

Exemple

Soit $X_1, X_2, \dots, X_n$ un échantillon aléatoire d'une v.a. X telle que $E(X) = \mu$ et $V(X) = \sigma^2$. Pour estimer μ , on considère $\hat{\mu} = \bar{X}$. On a $E(\bar{X}) = \mu$ et $V(\bar{X}) = \frac{\sigma^2}{n} \rightarrow 0$ lorsque $n \rightarrow \infty$. $\bar{X}$ est donc un estimateur convergent de μ .

Méthode des moments

Nous remarquons que la plupart des lois vues aux chapitres 5, 6 et 7, sont entièrement définies par un ou deux paramètres. Ces paramètres sont généralement liés aux deux premiers moments de la v.a. On peut citer par exemple :

Loi	Paramètres
Bernouilli	1 ^{er} moment
Géométrique	Inverse du 1 ^{er} moment
Poisson	1 ^{er} moment
Normale	Les deux premiers moments
Lognormale	Les deux premiers moments du logarithme
Exponentielle	Inverse du 1 ^{er} moment
Beta	2 paramètres fonctions des 2 premiers moments

Utilisation

Soit X est une v.a. continue ayant comme fonction de densité $f(x, \theta_1, \theta_2)$, ou une v.a discrète dont la fonction de masse est $p(x, \theta_1, \theta_2)$ et que cette v.a est définie à partir de ces deux premiers moments qui nous sont inconnus. Si $X_1, X_2, \dots, X_n$ est un échantillon aléatoire de taille n des valeurs de la v.a. X , on peut alors définir les deux premiers moments de cet échantillon par rapport à l'origine par :

$$m'_i = \frac{1}{n} \sum_{j=1}^n X_j^i, \quad i = 1, 2.$$

Ainsi, on peut estimer θ_i par résolution du système
 $E[X^i] = m'_i, i = 1, 2.$

Méthode du maximum de la vraisemblance

La méthode de maximum de la vraisemblance est l'une des meilleures méthodes d'estimation ponctuelle. Soit X une v.a. ayant comme fonction de probabilité $f(x, \theta)$ où θ représente un paramètre inconnu. Si $x_1, x_2, \dots, x_n$ est un échantillon de taille n des valeurs de la v.a. X , la fonction de vraisemblance de cet échantillon est alors :

$$L(\theta) = \prod_{i=1}^n f(x_i, \theta).$$

$\hat{\theta}$ l'estimateur du maximum de la vraisemblance de θ consiste à la valeur de θ telle que $L(\theta)$ est maximale. Il s'agit essentiellement de la valeur de θ qui maximise la probabilité d'obtenir les résultats fournis par l'échantillon.

Exemples

- ➊ Déterminer l'estimateur du paramètre de la loi de Poisson.
- ➋ Déterminer l'estimateur du paramètre de la loi exponentielles.
- ➌ Déterminer l'estimateur des paramètres de la loi normale.

Généralités

La méthode d'estimation d'un paramètre θ par intervalle de confiance consiste à déterminer deux statistiques $L(X_1, \dots, X_n)$ et $U(X_1, \dots, X_n)$ vérifiant l'égalité $P(L \leq \theta \leq U) = 1 - \alpha$. On l'appelle le niveau (ou le coefficient) de confiance. On le choisit généralement proche de 1. Généralement les bornes L et U s'obtiennent en posant $P(\theta < L) = \alpha/2$ et $P(\theta > U) = \alpha/2$. On obtient ainsi des intervalles de petite longueur (et généralement symétrique).

La méthode générale pour obtenir L et U consiste à considérer un estimateur $\hat{\theta}$ de θ et une fonction $H(\hat{\theta}, \theta)$ dont la distribution ne dépend d'aucun paramètre inconnu (fonction pivotale). On peut alors trouver deux nombres h_1 et h_2 vérifiant $P(h_1 \leq H(\hat{\theta}, \theta) \leq h_2) = 1 - \alpha$.

La forme exacte d'un intervalle de confiance dépend du paramètre à estimer et de la distribution de la variable considérée.

Intervalle de confiance pour une moyenne

Soit X une v.a de moyenne μ et de variance σ^2 et soit $X_1, \dots, X_n$ un échantillon aléatoire de taille n de X . Pour un niveau de confiance $1 - \alpha$ donné, les intervalles de confiance pour μ sont résumés dans le tableau suivant différentes situations (tableau I.C. P262).

Une moyenne μ		
σ^2 est connue et $X \sim N(\mu, \sigma^2)$, ou n grand	$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$	$\mu \in \bar{X} \pm z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$
σ^2 est inconnue et $X \sim N(\mu, \sigma^2)$	$\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim T_{n-1}$	$\mu \in \bar{X} \pm t_{\alpha/2, n-1} \cdot \frac{S}{\sqrt{n}}$
σ^2 est inconnue et n est très grand	$\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim N(0, 1)$	$\mu \in \bar{X} \pm z_{\alpha/2} \cdot \frac{S}{\sqrt{n}}$

Remarques

- Les intervalles donnés dans le tableau sont dits bilatéraux et symétriques. Pour un niveau $1 - \alpha$ fixé, les intervalles du tableau sont les plus courts. De plus, lorsque n augmente, la longueur de l'intervalle diminue et la précision augmente.
- Les intervalles de confiance unilatéraux de niveau $1 - \alpha$ se déduisent de ceux du tableau en considérant une seule borne de l'intervalle et en remplaçant $\alpha/2$ par α .
- Taille d'échantillon nécessaire : L'erreur d'estimation dans un intervalle de confiance pour μ est de $|\bar{X} - \mu|$. Lorsque la variance σ^2 est connue, on peut déterminer une taille d'échantillon nécessaire garantissant une erreur d'estimation d'au plus E , pour un niveau de confiance $1 - \alpha$ donné. Lorsque E est fixé, on doit avoir

$$|\bar{X} - \mu| \leq z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \leq E \Rightarrow n \geq \left(z_{\alpha/2} \frac{\sigma}{E} \right)^2.$$

Remarques (suite)

- Dans le cas où la variance σ^2 est inconnue, on remplace σ par l'écart type s de l'échantillon. Cette procédure est valide si X suit une loi normale (on a alors une loi T de Student à $\nu = n - 1$ d.d.l), ou si n est grand on a alors une loi normale.

Exemple

Le poids X des contenants d'un certain produit est une v.a de moyenne μ et d'écart type 0,3 grammes. Un échantillon aléatoire de 100 contenants est choisi et donne une moyenne de 49,7 grammes. Construire un I.C. pour μ de niveau

- ❶ $1 - \alpha = 0,95$
- ❷ $1 - \alpha = 0,99$
- ❸ Quelle taille d'échantillon doit-on prélever pour que l'erreur d'estimation soit d'au plus 0,04 au niveau de confiance $1 - \alpha = 0,90$.

Exemple

Un certain procédé est utilisé pour la production en série de pièces dont le poids X peut être approché par une distribution normale $N(\mu, \sigma^2)$. Un échantillon de 5 pièces prises au hasard dans la production du procédé est examiné et les poids suivants sont observés :

45,7 46,0 46,8 45,2 46,3 (en grammes)

- 1 Donner une estimation ponctuelle de μ .
- 2 Donner un I.C. pour μ au niveau de confiance 90%.
- 3 Donner un I.C. unilatéral (avec borne supérieure) pour μ au niveau de confiance 90%.

Intervalle de confiance pour une variance σ^2

Soit X une v.a de loi $N(\mu, \sigma^2)$, avec σ^2 inconnue, et soit $X_1, \dots, X_n$ un échantillon aléatoire de X . Pour un niveau de confiance $1 - \alpha$ fixé, l'I.C bilatéral de σ^2 est

$$\frac{(n-1)S^2}{\chi_{\alpha/2; n-1}^2} \leq \sigma^2 \leq \frac{(n-1)S^2}{\chi_{1-\alpha/2; n-1}^2}$$

Une variance σ^2		
$X \sim N(\mu, \sigma^2)$ et μ, σ^2 sont inconnues	$(n-1)\frac{S^2}{\sigma^2} \sim \chi_{n-1}^2$	$\frac{(n-1)S^2}{\chi_{\alpha/2; n-1}^2} \leq \sigma^2 \leq \frac{(n-1)S^2}{\chi_{1-\alpha/2; n-1}^2}$
Cas approximatif n est grand ($n \geq 40$)	$\frac{S - \sigma}{\sigma/\sqrt{2n}} \sim N(0, 1)$	$\frac{S}{1 + \frac{z_{\alpha/2}}{\sqrt{2n}}} \leq \sigma \leq \frac{S}{1 - \frac{z_{\alpha/2}}{\sqrt{2n}}}$

Remarques

Les I.C unilatéraux de niveau $1 - \alpha$ pour σ^2 sont

- $\frac{(n-1)S^2}{\chi_{\alpha;n-1}^2} \leq \sigma^2$
- $\sigma^2 \leq \frac{(n-1)S^2}{\chi_{1-\alpha;n-1}^2}$.
- Lorsque X n'est pas distribuée selon une loi normale, on peut utiliser l'approximation suivante si la taille d'échantillon est grande ($n \geq 40$) : $S \sim N(\sigma, \frac{\sigma^2}{2n})$.

On en déduit que pour un niveau de confiance $1 - \alpha$ fixé, un intervalle de confiance pour σ est

$$\frac{S}{1 + \frac{z_{\alpha/2}}{\sqrt{2n}}} \leq \sigma \leq \frac{S}{1 - \frac{z_{\alpha/2}}{\sqrt{2n}}}.$$

Intervalle de confiance pour une proportion p

Soit p la proportion de "succès" dans une population et soit $\hat{p}$ la proportion de "succès" dans un échantillon aléatoire de taille n . Pour un niveau $1 - \alpha$ fixé, un I.C (approximatif) pour p lorsque n est grand est :

$$\hat{p} - z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}} \leq p \leq \hat{p} + z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}.$$

Une proportion p		
$X \sim \text{Bernoulli}(p)$		
et n est très grand	$\frac{\hat{p} - p}{\sqrt{\frac{p(1-p)}{n}}} \sim N(0, 1)$	$p \in \hat{p} \pm z_{\alpha/2} \cdot \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}$

Remarques

- 1 Les I.C unilatéraux de niveau $1 - \alpha$ pour p se déduisent de celui du tableau en considérant une seule borne de l'intervalle et en remplaçant $\alpha/2$ par α .
 - $\hat{p} - z_\alpha \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \leq p$
 - $p \leq \hat{p} + z_\alpha \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$
- 2 L'erreur d'estimation dans un I.C pour p est de $|\hat{p} - p|$. On peut déterminer une taille d'échantillon nécessaire garantissant une erreur d'estimation d'au plus E , pour un niveau de confiance $1 - \alpha$ donné. On doit avoir

$$|\hat{p} - p| \leq z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \leq E \implies n \geq \left(\frac{z_{\alpha/2}}{E} \right)^2 p(1-p)$$

- 1 On dispose d'une estimation antérieure $\hat{p}_0$ de p , on prend $n \geq \left(\frac{z_{\alpha/2}}{E} \right)^2 \hat{p}_0(1 - \hat{p}_0)$.
- 2 On ne dispose d'aucune information sur p , on prend $p = 0,5$, et $n \geq \left(\frac{z_{\alpha/2}}{E} \right)^2 \frac{1}{4}$.

I.C pour une différence de deux moyennes $\mu_1 - \mu_2$

Soit X_1 et X_2 deux v.a (populations) de moyennes μ_1 et μ_2 et de variances σ_1^2 et σ_2^2 respectivement ; et soient $X_{11}, \dots, X_{1n_1}$ et $X_{21}, \dots, X_{2n_2}$ deux échantillons indépendants provenant de X_1 et X_2 respectivement.

Notons $\bar{X}_1$ et S_1^2 la moyenne et la variance de l'échantillon 1, et $\bar{X}_2$ et S_2^2 la moyenne et la variance de l'échantillon 2.

Pour un niveau de confiance $1 - \alpha$ donné, les intervalles de confiance pour la différence $\mu_1 - \mu_2$ sont résumés dans le tableau suivant différentes situations.

Estimation par intervalle de confiance (deux échantillons)

Situation	Loi utilisée	Intervalle
Une différence $\mu_1 - \mu_2$ σ_1^2 et σ_2^2 connues et $X_i \sim N(\mu_i, \sigma_i^2)$, $i = 1, 2$ ou alors n_1 et n_2 grands	$\frac{\bar{X}_1 - \bar{X}_2 - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim N(0, 1)$	$(\bar{X}_1 - \bar{X}_2) \pm z_{\alpha/2} \cdot \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}$
σ_1^2 et σ_2^2 inconnues avec $\sigma_1^2 = \sigma_2^2 = \sigma^2$ et $X_i \sim N(\mu_i, \sigma^2)$, $i = 1, 2$	$\frac{\bar{X}_1 - \bar{X}_2 - (\mu_1 - \mu_2)}{S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim T_{n_1+n_2-2}$	$(\bar{X}_1 - \bar{X}_2) \pm t_{\alpha/2; n_1+n_2-2} \cdot S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}$ où $S_p = \sqrt{\frac{(n_1-1)S_1^2 + (n_2-1)S_2^2}{n_1+n_2-2}}$
σ_1^2 et σ_2^2 inconnues avec $\sigma_1^2 \neq \sigma_2^2$ et $X_i \sim N(\mu_i, \sigma_i^2)$, $i = 1, 2$	$\frac{\bar{X}_1 - \bar{X}_2 - (\mu_1 - \mu_2)}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}} \sim T_\nu$	$(\bar{X}_1 - \bar{X}_2) \pm t_{\alpha/2; \nu} \cdot \sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}$ où $\nu = \frac{(S_1^2/n_1 + S_2^2/n_2)^2}{\frac{(S_1^2/n_1)^2}{n_1+1} + \frac{(S_2^2/n_2)^2}{n_2+1}} - 2$
σ_1^2 et σ_2^2 inconnues et n_1, n_2 grands ($n_1 \geq 30, n_2 \geq 30$)	$\frac{\bar{X}_1 - \bar{X}_2 - (\mu_1 - \mu_2)}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}} \sim N(0, 1)$	$(\bar{X}_1 - \bar{X}_2) \pm z_{\alpha/2} \cdot \sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}$
Observations couplées $D = X_1 - X_2 \sim \text{Normale}$ $D_j = X_{1j} - X_{2j}$, $j = 1, \dots, n$	$\frac{\bar{D} - (\mu_1 - \mu_2)}{S_D / \sqrt{n}} \sim T_{n-1}$	$\bar{D} \pm t_{\alpha/2; n-1} \cdot \frac{S_D}{\sqrt{n}}$ où $\bar{D} = \frac{1}{n} \sum_{j=1}^n D_j$, $S_D = \sqrt{\frac{1}{n-1} \sum_{j=1}^n (D_j - \bar{D})^2}$

Remarques

- 1 Les intervalles donnés dans le tableau sont dits bilatéraux et symétriques. Pour un niveau de confiance $1 - \alpha$ fixé, les intervalles du tableau sont plus courts. Les intervalles unilatéraux de niveau $1 - \alpha$ se déduisent de ceux du tableau en considérant une seule borne de l'intervalle et en remplaçant $\alpha/2$ par α .
- 2 L'erreur d'estimation dans un intervalle de confiance pour la différence $\mu_1 - \mu_2$ est de $|\bar{X}_1 - \bar{X}_2 - (\mu_1 - \mu_2)|$. Lorsque les variances σ_1^2 et σ_2^2 sont connues, on peut déterminer une taille d'échantillon nécessaire n (la même pour les deux échantillons) garantissant une erreur d'estimation d'au plus E , pour un niveau de confiance $1 - \alpha$ donné. En effet, si $n_1 = n_2 = n$, on a $|\bar{X}_1 - \bar{X}_2 - (\mu_1 - \mu_2)| \leq \frac{z_{\alpha/2}}{\sqrt{n}} \times \sqrt{\sigma_1^2 + \sigma_2^2} \leq E \implies n \geq \left(\frac{z_{\alpha/2}}{E} \times \sqrt{\sigma_1^2 + \sigma_2^2} \right)^2$.

Exemple

Une analyse statistique descriptive des données sur des mesures de diamètre (en cm) des pièces produites par deux chaînes de production (A et B) a donné les résultats suivants :

Chaîne	A	B
nombre d'observations	51	51
moyenne : $\bar{x}$	1,375147	1,374982
écart-type : s	0,000167	0,000172

Soit X_1 (X_2) le diamètre des pièces produites par la chaîne A (B).
 $E(X_1) = \mu_1$, $E(X_2) = \mu_2$, $V(X_1) = \sigma_1^2$, $V(X_2) = \sigma_2^2$.

- 1 Donner un intervalle de confiance pour $\mu_1 - \mu_2$ au niveau de confiance 95%.
- 2 Donner un intervalle de confiance unilatéral (avec borne inférieure) pour $\mu_1 - \mu_2$ au niveau de confiance 95%.

I.C pour un rapport de deux variances σ_1^2/σ_2^2

Soit X_1 et X_2 deux v.a telles que $X_1 \sim N(\mu_1, \sigma_1^2)$ et $X_2 \sim N(\mu_2, \sigma_2^2)$, et soit $X_{11}, \dots, X_{1n_1}$ et $X_{21}, \dots, X_{2n_2}$ deux échantillons indépendants provenant de X_1 et X_2 respectivement. Pour un niveau de confiance $1 - \alpha$ donné, l'intervalle de confiance bilatéral pour le rapport σ_1^2/σ_2^2 est

$$\frac{S_1^2}{S_2^2} F_{1-\alpha/2; n_2-1, n_1-1} \leq \frac{\sigma_1^2}{\sigma_2^2} \leq \frac{S_1^2}{S_2^2} F_{\alpha/2; n_2-1, n_1-1}.$$

Exemple

On dispose de deux méthodes (A et B) pour la fabrication d'un produit. On s'intéresse au temps nécessaire pour fabriquer une unité du produit. Une analyse statistique descriptive a donné les résultats préliminaires suivants

Méthode	A	B
Taille d'échantillon	12	16
Écart-type s	0,85	0,98

Soit X_1 (X_2) le temps requis par le procédé A (B).

$X_1 \sim N(\mu_1, \sigma_1^2)$, $X_2 \sim N(\mu_2, \sigma_2^2)$.

- 1 Donner un intervalle de confiance pour le rapport $\frac{\sigma_1^2}{\sigma_2^2}$ au niveau de confiance $1 - \alpha = 0,90$.
- 2 Donner un intervalle de confiance unilatéral (avec borne inférieure) pour le rapport $\frac{\sigma_1^2}{\sigma_2^2}$ au niveau de confiance $1 - \alpha = 0,90$.

Les intervalles de prévision

Soit $X_1, \dots, X_n$ un échantillon aléatoire d'une v.a X de loi normale $N(\mu, \sigma^2)$. On cherche parfois à prédire la future observation, disons X_{n+1} de X . On estime ponctuellement une telle observation par $\bar{X}$. Pour un niveau de confiance $1 - \alpha$ fixé, l'intervalle de confiance pour X_{n+1} est

$$X_{n+1} \in \bar{X} \pm t_{\alpha/2; n-1} \sqrt{S^2(1 + \frac{1}{n})}.$$

Les intervalles unilatéraux de niveau $1 - \alpha$ sont :

- $X_{n+1} \geq \bar{X} - t_{\alpha; n-1} \sqrt{S^2(1 + \frac{1}{n})}$, cas unilatéral avec borne inférieure ;
- $X_{n+1} \leq \bar{X} + t_{\alpha; n-1} \sqrt{S^2(1 + \frac{1}{n})}$, cas unilatéral avec borne supérieure.

Exemple 10.27

On a mesuré au cours de 10 vols l'accélération maximale (en g) d'un avion de ligne assurant une certaine liaison. Voici les résultats obtenus :

1,15 1,23 1,56 1,69 1,71 1,83 1,83 1,85 1,90 1,91

On a $\bar{X} = 1,666$, $s = 0,273$. Donner un intervalle de prédiction de l'accélération maximale que l'avion subira lors de son prochain vol.

Les intervalles de tolérance

Un intervalle de tolérance (statistique) d'une v.a X est un intervalle calculé à partir des données d'un échantillon aléatoire $X_1, \dots, X_n$ de X , qui contient (au moins) un pourcentage q (taux de couverture) des valeurs de X , avec une grande probabilité $1 - \alpha$ (coefficient de confiance). On distingue deux méthodes selon que X suit une loi normale ou non.

Cas où X suit une loi quelconque

Lorsque X est distribuée selon une loi quelconque mais de type continu, on considère

- $X_{min} = X_{(1)} = \min\{X_1, \dots, X_n\}$
- $X_{max} = X_{(n)} = \max\{X_1, \dots, X_n\}$

Il est alors démontré que $[X_{min}, X_{max}]$ constitue un intervalle de tolérance pour la v.a X . Le taux de couverture $q = P$ et le niveau de confiance $1 - \alpha$ de cet intervalle sont tels que

$$1 - \alpha = 1 - nP^{n-1} + (n-1)P^n.$$

On a donc deux possibilités

- 1 Déterminer $1 - \alpha$ lorsque P et n sont connus ;
- 2 Déterminer n approximativement, lorsque $1 - \alpha$ et P sont connus, par $n = \frac{1}{2} + \frac{1+P}{1-P} \frac{\chi_4^2(\alpha)}{4}.$