

# Test de conformité à une loi théorique

## Test de conformité (d'adéquation) du Khi2

Il s'agit de comparer une loi théorique à une distribution expérimentale.

On considère une v.a.  $X$  et on désire tester l'ajustement de sa loi notée  $\mathcal{L}$  à une loi connue  $\mathcal{L}_0$ . On va alors tester

$$H_0 : \mathcal{L} = \mathcal{L}_0 \text{ contre } H_1 : \mathcal{L} \neq \mathcal{L}_0.$$

Pour cela on se donne dans la population  $n$  observations de la variable  $X$  partagées en  $k$  classes. On désigne par  $O_i$  l'effectif observé de la classe  $i$ .

Pour chaque classe l'effectif théorique est défini par

$$C_i = n \cdot \mathbb{P}(X \in \text{classe}_i / X \rightsquigarrow \mathcal{L}_0).$$

# Test de conformité à une loi théorique

## Test de conformité (d'adéquation) du Khi2

On établit alors le tableau suivant en imposant que  $C_i \geq 5$

| Classe             | 1     | 2     |  | $i$   |  | $k$   |
|--------------------|-------|-------|--|-------|--|-------|
| Effectif observé   | $O_1$ | $O_2$ |  | $O_i$ |  | $O_k$ |
| Effectif théorique | $C_1$ | $C_2$ |  | $C_i$ |  | $C_k$ |

Sous l'hypothèse  $H_0$  la statistique  $K$  qui prend sur tout l'échantillon de taille  $n$  la valeur

$$\chi_c^2 = \sum_{i=1}^k \frac{(O_i - C_i)^2}{C_i} \rightsquigarrow \chi^2 (\nu = k - 1 - r)$$

$r$  est le nombre de paramètres de la loi  $\mathcal{L}_0$  qu'on a du estimer.

**Décision :** On compare la valeur  $\chi_c^2$  à la valeur théorique  $\chi_\alpha^2 (\nu)$ .

On rejette  $H_0$  si  $\chi_c^2 > \chi_\alpha^2$ .

# Test de conformité à une loi théorique

## Test de Kolmogorov-Smirnov

On considère un échantillon de taille  $n$  d'observations d'une variable et une fonction de répartition de référence  $F(x)$ .

Le test de Kolmogorov consiste à tester l'hypothèse  $H_0$  selon laquelle l'échantillon a été prélevé dans une population de fonction de répartition  $F(x)$ .

On calcule la statistique de Kolmogorov-Smirnov

$$D_n = \sup_{x \in \mathbb{R}} |F_n(x) - F(x)|$$

dont la distribution est connue sous  $H_0$ .

**Décision :** Si  $D_n > \frac{c}{\sqrt{n}}$ , on rejette  $H_0$ ,  $c$  étant une valeur tabulée dépendant de  $n$  et de  $\alpha$ .

# Test de conformité à une loi théorique

## Test de normalité

C'est une méthode pour visualiser les chances qu'a une distribution d'être gaussienne. Pour cela on procède en six étapes

- 1 On ordonne les données  $x_{(i)}$ ;
- 2 On calcule les fréquences cumulées modifiées  $F_i = \frac{i - \frac{3}{8}}{n + \frac{1}{4}}$ ;
- 3 On calcule les réels  $u_i = \phi^{-1}(F_i)$ ;
- 4 On construit le nuage de points  $(x_{(1)}, u_1), (x_{(2)}, u_2), \dots, (x_{(n)}, u_n)$  et on vérifie si les points sont alignés;
- 5 On peut confirmer le résultat en calculant le coefficient de corrélation linéaire  $R = \frac{\text{Cov}(X, U)}{\sigma_X \sigma_U}$ ;
- 6 On compare la valeur de  $R$  avec la valeur critique  $r_0$ , et on accepte l'hypothèse si  $R \geq r_0$ .

# Test de conformité à une loi théorique

## Example

En lançant 60 fois un dé, un joueur obtient les résultats suivants :

|           |    |   |   |    |   |    |
|-----------|----|---|---|----|---|----|
| Faces     | 1  | 2 | 3 | 4  | 5 | 6  |
| Effectifs | 15 | 7 | 4 | 11 | 6 | 17 |

Le dé est-il truqué ?

# Test de conformité à une loi théorique

## Exemple

On réalise des essais de greffage sur 3000 échantillon comportant chacun 6 arbustes identiques sur lesquels on implante un greffon. On note  $X$  la v.a. qui prend pour valeurs le nombre  $x$  de réussite dans chaque échantillon.

|                       |     |     |     |     |     |    |   |
|-----------------------|-----|-----|-----|-----|-----|----|---|
| Nombre de réussites   | 0   | 1   | 2   | 3   | 4   | 5  | 6 |
| Nombre d'échantillons | 702 | 977 | 710 | 402 | 153 | 48 | 8 |

Est-ce que l'hypothèse que la v.a.  $X$  suit une loi de Poisson de paramètre  $\lambda$  inconnu est acceptable au risque  $\alpha = 0,05$ ?

# Test de conformité à une loi théorique

## Exemple

On relève la taille de 300 individus et on obtient le tableau suivant :

|           |              |              |              |              |
|-----------|--------------|--------------|--------------|--------------|
| Classes   | $[155, 160[$ | $[160, 165[$ | $[165, 170[$ | $[170, 175[$ |
| Effectifs | 3            | 6            | 33           | 105          |
| Classes   | $[175, 180[$ | $[180, 185[$ | $[185, 190[$ |              |
| Effectifs | 99           | 48           | 6            |              |

Tester la normalité de la distribution de la taille des individus.

# Test de conformité d'une proportion

## Test unilatéral 1

On désire tester  $H_0 : p = p_0$  contre  $H_1 : p > p_0$   
(même procédure pour tester  $H_0 : p \leq p_0$  contre  $H_1 : p > p_0$ )

|                          |                                                                                            |
|--------------------------|--------------------------------------------------------------------------------------------|
| Statistique              | $Z = \frac{\sqrt{n}(\hat{p} - p_0)}{\sqrt{p_0(1-p_0)}} \rightsquigarrow \mathcal{N}(0, 1)$ |
| Intervalle d'acceptation | $I_\alpha = ]-\infty, z_{1-\alpha}]$                                                       |

$1 - \alpha = \mathbb{P}_{H_0} \{Z \leq z_{1-\alpha}\}$ , avec  $\hat{p}$  la valeur estimée de la proportion.

# Test de conformité d'une proportion

## Test unilatéral 2

On désire tester  $H_0 : p = p_0$  contre  $H_1 : p < p_0$   
(même procédure pour tester  $H_0 : p \geq p_0$  contre  $H_1 : p < p_0$ )

|                          |                                                                                            |
|--------------------------|--------------------------------------------------------------------------------------------|
| Statistique              | $Z = \frac{\sqrt{n}(\hat{p} - p_0)}{\sqrt{p_0(1-p_0)}} \rightsquigarrow \mathcal{N}(0, 1)$ |
| Intervalle d'acceptation | $I_\alpha = [-z_{1-\alpha}, +\infty[$                                                      |

$1 - \alpha = \mathbb{P}_{H_0} \{Z \geq -z_{1-\alpha}\}$ , avec  $\hat{p}$  la valeur estimée de la proportion.

# Test de conformité d'une proportion

## Test bilatéral

On désire tester  $H_0 : p = p_0$  contre  $H_1 : p \neq p_0$

|                          |                                                                                            |
|--------------------------|--------------------------------------------------------------------------------------------|
| Statistique              | $Z = \frac{\sqrt{n}(\hat{p} - p_0)}{\sqrt{p_0(1-p_0)}} \rightsquigarrow \mathcal{N}(0, 1)$ |
| Intervalle d'acceptation | $I_\alpha = \left[ -z_{1-\frac{\alpha}{2}}, z_{1-\frac{\alpha}{2}} \right]$                |

$1 - \alpha = \mathbb{P}_{H_0} \left\{ -z_{1-\frac{\alpha}{2}} \leq Z \leq z_{1-\frac{\alpha}{2}} \right\}$ , avec  $\hat{p}$  la valeur estimée de la proportion.

# Test de comparaison de deux proportions

## Test unilatéral 1

On désire tester  $H_0 : p_1 = p_2$  contre  $H_1 : p_1 > p_2$   
(même procédure pour tester  $H_0 : p_1 \leq p_2$  contre  $H_1 : p_1 > p_2$ )

|                          |                                                                                                                                |
|--------------------------|--------------------------------------------------------------------------------------------------------------------------------|
| Statistique              | $Z = \frac{f_1 - f_2}{\sqrt{\hat{p}(1-\hat{p})\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}} \rightsquigarrow \mathcal{N}(0, 1)$ |
| Intervalle d'acceptation | $I_\alpha = ]-\infty, z_{1-\alpha}]$                                                                                           |

$$1 - \alpha = \mathbb{P}_{H_0} \{Z \leq z_{1-\alpha}\}, \text{ avec } \hat{p} = \frac{n_1 f_1 + n_2 f_2}{n_1 + n_2}.$$

# Test de comparaison de deux proportions

## Test unilatéral 2

On désire tester  $H_0 : p_1 = p_2$  contre  $H_1 : p_1 < p_2$   
(même procédure pour tester  $H_0 : p_1 \geq p_2$  contre  $H_1 : p_1 < p_2$ )

|                          |                                                                                                                                |
|--------------------------|--------------------------------------------------------------------------------------------------------------------------------|
| Statistique              | $Z = \frac{f_1 - f_2}{\sqrt{\hat{p}(1-\hat{p})\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}} \rightsquigarrow \mathcal{N}(0, 1)$ |
| Intervalle d'acceptation | $I_\alpha = [-z_{1-\alpha}, +\infty[$                                                                                          |

$$1 - \alpha = \mathbb{P}_{H_0} \{Z \geq -z_{1-\alpha}\}, \text{ avec } \hat{p} = \frac{n_1 f_1 + n_2 f_2}{n_1 + n_2}.$$

# Test de comparaison de deux proportions

## Test bilatéral

On désire tester  $H_0 : p_1 = p_2$  contre  $H_1 : p_1 \neq p_2$

|                          |                                                                                                                                |
|--------------------------|--------------------------------------------------------------------------------------------------------------------------------|
| Statistique              | $Z = \frac{f_1 - f_2}{\sqrt{\hat{p}(1-\hat{p})\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}} \rightsquigarrow \mathcal{N}(0, 1)$ |
| Intervalle d'acceptation | $I_\alpha = \left[-z_{1-\frac{\alpha}{2}}, z_{1-\frac{\alpha}{2}}\right]$                                                      |

$$1 - \alpha = \mathbb{P}_{H_0} \left\{ -z_{1-\frac{\alpha}{2}} \leq Z \leq z_{1-\frac{\alpha}{2}} \right\}, \text{ avec } \hat{p} = \frac{n_1 f_1 + n_2 f_2}{n_1 + n_2}.$$

# Test de conformité d'une moyenne

## Test unilatéral 1

On désire tester  $H_0 : \mu = \mu_0$  contre  $H_1 : \mu > \mu_0$   
(même procédure pour tester  $H_0 : \mu \leq \mu_0$  contre  $H_1 : \mu > \mu_0$ )

- $\sigma$  connue

|                          |                                                                                      |
|--------------------------|--------------------------------------------------------------------------------------|
| Statistique              | $Z = \frac{\bar{X} - \mu_0}{\sigma_0 / \sqrt{n}} \rightsquigarrow \mathcal{N}(0, 1)$ |
| Intervalle d'acceptation | $I_\alpha = ]-\infty, z_{1-\alpha}]$                                                 |

$$1 - \alpha = \mathbb{P}_{H_0} \{ Z \leq z_{1-\alpha} \}$$

- ●  $\sigma$  inconnue

|                          |                                                                                 |
|--------------------------|---------------------------------------------------------------------------------|
| Statistique              | $T = \frac{\bar{X} - \mu_0}{S / \sqrt{n-1}} \rightsquigarrow \mathcal{T}_{n-1}$ |
| Intervalle d'acceptation | $I_\alpha = ]-\infty, t_{1-\alpha}]$                                            |

$$1 - \alpha = \mathbb{P}_{H_0} \{ T \leq t_{1-\alpha} \}$$

# Test de conformité d'une moyenne

## Test unilatéral 2

On désire tester  $H_0 : \mu = \mu_0$  contre  $H_1 : \mu < \mu_0$   
(même procédure pour tester  $H_0 : \mu \geq \mu_0$  contre  $H_1 : \mu < \mu_0$ )

### ■ $\sigma$ connue

|                          |                                                                                      |
|--------------------------|--------------------------------------------------------------------------------------|
| Statistique              | $Z = \frac{\bar{X} - \mu_0}{\sigma_0 / \sqrt{n}} \rightsquigarrow \mathcal{N}(0, 1)$ |
| Intervalle d'acceptation | $I_\alpha = [-z_{1-\alpha}, +\infty[$                                                |

$$1 - \alpha = \mathbb{P}_{H_0} \{ Z \geq -z_{1-\alpha} \}$$

### ■ $\sigma$ inconnue

|                          |                                                                                 |
|--------------------------|---------------------------------------------------------------------------------|
| Statistique              | $T = \frac{\bar{X} - \mu_0}{S / \sqrt{n-1}} \rightsquigarrow \mathcal{T}_{n-1}$ |
| Intervalle d'acceptation | $I_\alpha = [-t_{1-\alpha}, +\infty[$                                           |

$$1 - \alpha = \mathbb{P}_{H_0} \{ T \geq -t_{1-\alpha} \}$$

# Test de conformité d'une moyenne

## Test bilatéral

On désire tester  $H_0 : \mu = \mu_0$  contre  $H_1 : \mu \neq \mu_0$

■  $\sigma$  connue

|                          |                                                                                      |
|--------------------------|--------------------------------------------------------------------------------------|
| Statistique              | $Z = \frac{\bar{X} - \mu_0}{\sigma_0 / \sqrt{n}} \rightsquigarrow \mathcal{N}(0, 1)$ |
| Intervalle d'acceptation | $I_\alpha = \left[ -z_{1-\frac{\alpha}{2}}, z_{1-\frac{\alpha}{2}} \right]$          |

$$1 - \alpha = \mathbb{P}_{H_0} \left\{ -z_{1-\frac{\alpha}{2}} \leq Z \leq z_{1-\frac{\alpha}{2}} \right\}$$

■  $\sigma$  inconnue

|                          |                                                                                 |
|--------------------------|---------------------------------------------------------------------------------|
| Statistique              | $T = \frac{\bar{X} - \mu_0}{S / \sqrt{n-1}} \rightsquigarrow \mathcal{T}_{n-1}$ |
| Intervalle d'acceptation | $I_\alpha = \left[ -t_{1-\frac{\alpha}{2}}, t_{1-\frac{\alpha}{2}} \right]$     |

$$1 - \alpha = \mathbb{P}_{H_0} \left\{ -t_{1-\frac{\alpha}{2}} \leq T \leq t_{1-\frac{\alpha}{2}} \right\}$$

# Test de comparaison de deux moyennes

## Test unilatéral 1

On désire tester  $H_0 : \mu_1 = \mu_2$  contre  $H_1 : \mu_1 > \mu_2$   
(même procédure pour tester  $H_0 : \mu_1 \leq \mu_2$  contre  $H_1 : \mu_1 > \mu_2$ )

### ■ $\sigma$ connue

|                          |                                                                                                                               |
|--------------------------|-------------------------------------------------------------------------------------------------------------------------------|
| Statistique              | $Z = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \rightsquigarrow \mathcal{N}(0, 1)$ |
| Intervalle d'acceptation | $I_\alpha = ]-\infty, z_{1-\alpha}]$                                                                                          |

### ■ $\sigma$ inconnue

|                          |                                                                                                                                                                                             |
|--------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Statistique              | $T = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\left(\frac{1}{n_1} + \frac{1}{n_2}\right) \left(\frac{n_1 s_1^2 + n_2 s_2^2}{n_1 + n_2 - 2}\right)}} \rightsquigarrow \mathcal{T}_{n_1 + n_2 - 2}$ |
| Intervalle d'acceptation | $I_\alpha = ]-\infty, t_{1-\alpha}]$                                                                                                                                                        |

# Test de comparaison de deux moyennes

## Test unilatéral 2

On désire tester  $H_0 : \mu_1 = \mu_2$  contre  $H_1 : \mu_1 < \mu_2$   
(même procédure pour tester  $H_0 : \mu_1 \geq \mu_2$  contre  $H_1 : \mu_1 < \mu_2$ )

### ■ $\sigma$ connue

|                          |                                                                                                                               |
|--------------------------|-------------------------------------------------------------------------------------------------------------------------------|
| Statistique              | $Z = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \rightsquigarrow \mathcal{N}(0, 1)$ |
| Intervalle d'acceptation | $I_\alpha = [-z_{1-\alpha}, +\infty[$                                                                                         |

### ■ $\sigma$ inconnue

|                          |                                                                                                                                                                                             |
|--------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Statistique              | $T = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\left(\frac{1}{n_1} + \frac{1}{n_2}\right) \left(\frac{n_1 s_1^2 + n_2 s_2^2}{n_1 + n_2 - 2}\right)}} \rightsquigarrow \mathcal{T}_{n_1 + n_2 - 2}$ |
| Intervalle d'acceptation | $I_\alpha = [-t_{1-\alpha}, +\infty[$                                                                                                                                                       |

# Test de comparaison de deux moyennes

## Test bilatéral

On désire tester  $H_0 : \mu_1 = \mu_2$  contre  $H_1 : \mu_1 \neq \mu_2$

### ■ $\sigma$ connue

|                          |                                                                                                                               |
|--------------------------|-------------------------------------------------------------------------------------------------------------------------------|
| Statistique              | $Z = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \rightsquigarrow \mathcal{N}(0, 1)$ |
| Intervalle d'acceptation | $I_\alpha = \left[ -z_{1-\frac{\alpha}{2}}, z_{1-\frac{\alpha}{2}} \right]$                                                   |

### ■ $\sigma$ inconnue

|                          |                                                                                                                                                                                             |
|--------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Statistique              | $T = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\left(\frac{1}{n_1} + \frac{1}{n_2}\right) \left(\frac{n_1 S_1^2 + n_2 S_2^2}{n_1 + n_2 - 2}\right)}} \rightsquigarrow \mathcal{T}_{n_1 + n_2 - 2}$ |
| Intervalle d'acceptation | $I_\alpha = \left[ -t_{1-\frac{\alpha}{2}}, t_{1-\frac{\alpha}{2}} \right]$                                                                                                                 |

# Test de conformité d'une variance

## Test unilatéral 1

On désire tester  $H_0 : \sigma = \sigma_0$  contre  $H_1 : \sigma > \sigma_0$   
(même procédure pour tester  $H_0 : \sigma \leq \sigma_0$  contre  $H_1 : \sigma > \sigma_0$ )

|                          |                                                             |
|--------------------------|-------------------------------------------------------------|
| Statistique              | $K = \frac{nS^2}{\sigma_0^2} \rightsquigarrow \chi_{n-1}^2$ |
| Intervalle d'acceptation | $I_\alpha = [0, k_{1-\alpha}]$                              |

$$\alpha = \mathbb{P}_{H_0} \{K > k_{1-\alpha}\}$$

# Test de conformité d'une variance

## Test unilatéral 2

On désire tester  $H_0 : \sigma = \sigma_0$  contre  $H_1 : \sigma < \sigma_0$   
(même procédure pour tester  $H_0 : \sigma \geq \sigma_0$  contre  $H_1 : \sigma < \sigma_0$ )

|                          |                                                             |
|--------------------------|-------------------------------------------------------------|
| Statistique              | $K = \frac{nS^2}{\sigma_0^2} \rightsquigarrow \chi_{n-1}^2$ |
| Intervalle d'acceptation | $I_\alpha = [k_\alpha, +\infty[$                            |

$$\alpha = \mathbb{P}_{H_0} \{K < k_\alpha\}$$

# Test de conformité d'une variance

## Test bilatéral

On désire tester  $H_0 : \sigma = \sigma_0$  contre  $H_1 : \sigma \neq \sigma_0$

|                          |                                                             |
|--------------------------|-------------------------------------------------------------|
| Statistique              | $K = \frac{nS^2}{\sigma_0^2} \rightsquigarrow \chi_{n-1}^2$ |
| Intervalle d'acceptation | $I_\alpha = [k_{\frac{\alpha}{2}}, k_{1-\frac{\alpha}{2}}]$ |

$$\alpha/2 = \mathbb{P}_{H_0} \left\{ K \leq k_{\frac{\alpha}{2}} \right\} \text{ et } \alpha/2 = \mathbb{P}_{H_0} \left\{ K \geq k_{1-\frac{\alpha}{2}} \right\}$$

# Test de comparaison de deux variances

## Test unilatéral 1

On désire tester  $H_0 : \sigma_1 = \sigma_2$  contre  $H_1 : \sigma_1 > \sigma_2$   
(même procédure pour tester  $H_0 : \sigma_1 \leq \sigma_2$  contre  $H_1 : \sigma_1 > \sigma_2$ )

|                          |                                                                                                                  |
|--------------------------|------------------------------------------------------------------------------------------------------------------|
| Statistique              | $F = \frac{\frac{n_1 S_1^2}{n_1 - 1}}{\frac{n_2 S_2^2}{n_2 - 1}} \rightsquigarrow \mathcal{F}(n_1 - 1, n_2 - 1)$ |
| Intervalle d'acceptation | $I_\alpha = [0, f_{1-\alpha}]$                                                                                   |

# Test de comparaison de deux variances

## Test unilatéral 2

On désire tester  $H_0 : \sigma_1 = \sigma_2$  contre  $H_1 : \sigma_1 < \sigma_2$   
(même procédure pour tester  $H_0 : \sigma_1 \geq \sigma_2$  contre  $H_1 : \sigma_1 < \sigma_2$ )

|                          |                                                                                                                  |
|--------------------------|------------------------------------------------------------------------------------------------------------------|
| Statistique              | $F = \frac{\frac{n_1 S_1^2}{n_1 - 1}}{\frac{n_2 S_2^2}{n_2 - 1}} \rightsquigarrow \mathcal{F}(n_1 - 1, n_2 - 1)$ |
| Intervalle d'acceptation | $I_\alpha = [f_\alpha, +\infty[$                                                                                 |

# Test de comparaison de deux variances

## Test bilatéral

On désire tester  $H_0 : \sigma_1 = \sigma_2$  contre  $H_1 : \sigma_1 \neq \sigma_2$

|                          |                                                                                                                  |
|--------------------------|------------------------------------------------------------------------------------------------------------------|
| Statistique              | $F = \frac{\frac{n_1 S_1^2}{n_1 - 1}}{\frac{n_2 S_2^2}{n_2 - 1}} \rightsquigarrow \mathcal{F}(n_1 - 1, n_2 - 1)$ |
| Intervalle d'acceptation | $I_\alpha = \left[ f_{\frac{\alpha}{2}}, f_{1 - \frac{\alpha}{2}} \right]$                                       |

$$\alpha/2 = \mathbb{P}_{H_0} \left\{ Z \leq f_{\frac{\alpha}{2}} \right\} \text{ et } \alpha/2 = \mathbb{P}_{H_0} \left\{ Z \geq f_{1 - \frac{\alpha}{2}} \right\}.$$

# Examples

## Example

Une machine a produit dans le passé des rondelles ayant une épaisseur de 0,05 cm. Pour déterminer si la machine est encore en état de marche, on choisit un échantillon de 10 rondelles dont les épaisseurs ont une moyenne de 0,053 cm et un écart-type de 0,003 cm.

Tester l'hypothèse qui affirme que la machine est en état de marche au seuil de signification  $\alpha = 0,05$  et  $\alpha = 0,01$ .

# Exemples

## Example

Deux groupes  $A$  et  $B$ , se composent chacun de 100 personnes atteintes d'une même maladie. On administre du sérum au groupe  $A$  mais pas au groupe  $B$  (que l'on appelle le groupe de contrôle); mais les deux groupes sont traités de la même manière. On a remarqué que 75 malades du groupe  $A$  et 65 du groupe  $B$  ont guéri.

- 1 Tester l'hypothèse que le sérum est une aide efficace dans la guérison de la maladie, en considérant un niveau de signification  $\alpha$  de 0,01; 0,05 et 0,1.
- 2 Refaire le même test en considérant des groupes de 300 personnes, sachant qu'il y a eu 225 personnes guéris dans le groupe  $A$  et 195 personnes dans le groupe  $B$ .



# Exemples

## Example

Dans deux départements ( $A$  et  $B$ ) de mathématiques, les notes de statistique des étudiants suivent des lois normales dont les écart-type sont  $\sigma_A$  et  $\sigma_B$ . Un échantillon de  $n_A = 9$  notes d'étudiants de département  $A$  a donné un écart-type  $S_A = 5$ . Un échantillon de  $n_B = 25$  notes d'étudiants de département  $B$  a donné un écart-type  $S_B = 3$ .

Tester l'hypothèse  $H_0 : \sigma_A^2 = \sigma_B^2$  contre l'hypothèse  $H_1 : \sigma_A^2 \neq \sigma_B^2$  au risque  $\alpha$  de 0,01; 0,05 et 0,1.

# Test de Mann et Whitney

On dispose des mesures des valeurs de  $X$  dans deux échantillons indépendants  $E_1$  et  $E_2$ , de tailles respectives  $n_1$  et  $n_2$ . On souhaite comparer les deux moyennes expérimentales, c'est-à-dire tester l'hypothèse nulle  $H_0 : \mu_1 = \mu_2$ .

On commence par trier les valeurs obtenues dans la réunion des deux échantillons par ordre croissant. Pour chaque valeur  $x_i$  issue de  $E_1$ , on compte le nombre de valeurs issues de  $E_2$  situées après lui dans la liste ordonnée (celles qui sont égales à  $x_i$  ne comptent que pour  $\frac{1}{2}$ ). On note  $u_1$  la somme des nombres ainsi associés aux différentes valeurs issues de  $E_1$ . On fait de même en échangeant les rôles des deux échantillons, ce qui donne la somme  $u_2$ .

# Test de Mann et Whitney

Soit  $u$  la plus petite des deux sommes obtenues :

$$u = \min \{u_1, u_2\}.$$

On note  $U$  la variable aléatoire associée.

- Pour  $n_1$  et  $n_2$  quelconques, on lit dans les tables du test de Mann et Whitney le nombre  $m_\alpha$  tel que, sous  $H_0$ ,  $\mathbb{P}(U \leq m_\alpha) = \alpha$ . On rejette  $H_0$  au risque d'erreur  $\alpha$  si  $u \leq m_\alpha$ .
- Si  $n_1$  et  $n_2$  sont assez grands (20 en général), sous  $H_0$ ,  $U$  suit approximativement la loi  $\mathcal{N}(\mu, \sigma)$  avec

$$\mu = \frac{n_1 n_2}{2} \text{ et } \sigma = \sqrt{\frac{n_1 n_2 (n_1 + n_2 + 1)}{12}}$$

On lit  $u_\alpha$  dans la table de l'écart réduit de la loi normale tel que  $\mathbb{P}(|U| \geq u_\alpha) = \alpha$ , on calcule  $z = \frac{u - \mu}{\sigma}$  et on rejette  $H_0$  au risque d'erreur  $\alpha$  si  $z \notin ]-z_\alpha, z_\alpha[$ .

# Test de Wilcoxon

On dispose de deux échantillons appariés  $E_1$  et  $E_2$ , c'est-à-dire que chaque valeur de  $E_1$  est associée à une valeur de  $E_2$ . On teste l'hypothèse nulle  $H_0 : \mu_1 = \mu_2$ .

On calcule les différences entre les valeurs appariées, puis on les classe par ordre croissant des valeurs absolues, en omettant les différences nulles. On affecte à chaque différence non nulle son rang dans le classement (ou la moyenne de ses rangs en cas d'ex-æquo). On note  $w_+$  la somme des rangs des différences strictement positives,  $w_-$  la somme des rangs des différences strictement négatives; on vérifie que

$$w_+ + w_- = \frac{N(N+1)}{2},$$

où  $N$  désigne le nombre de différences non nulles.

# Test de Wilcoxon

On note  $w = \min \{w_+, w_-\}$  et soit  $W$  la variable aléatoire associée.

- Si  $N \leq 25$ , on lit dans les tables du test de Wilcoxon le nombre  $w_\alpha$  tel que, sous  $H_0$ ,  $\mathbb{P}(U \geq w_\alpha) = \alpha$ . On rejette  $H_0$  au risque d'erreur  $\alpha$  si  $w \geq w_\alpha$ .
- Si  $N > 25$ , sous  $H_0$ ,  $W$  suit approximativement la  $\mathcal{N}(\mu, \sigma)$  avec

$$\mu = \frac{N(N+1)}{2} \text{ et } \sigma = \sqrt{\frac{N(N+1)(2N+1)}{24}},$$

on calcule  $z = \frac{w - \mu}{\sigma}$  et on la compare à  $z_\alpha$  lu dans la table de la loi normale centrée réduite. On conclut comme à l'habitude.

## Example

Comparer les moyennes des échantillons :

|    |    |     |     |    |    |    |    |     |    |    |
|----|----|-----|-----|----|----|----|----|-----|----|----|
| E1 | 30 | 98  | 20  | 52 | 36 | 59 | 85 | 94  |    |    |
| E2 | 93 | 125 | 113 | 76 | 32 | 86 | 72 | 142 | 96 | 38 |

On ne dispose d'aucune hypothèse sur la loi suivie par la variable aléatoire étudiée au niveau des populations.

## Example

Un chimiste a mis au point une méthode de dosage du principe actif contenu dans des comprimés pharmaceutiques. Il décide de la comparer à une méthode de référence. Pour cela il dose 12 comprimés par les deux méthodes, avec les résultats suivants (quantité de principe actif en mg, pour chaque comprimé) :

| $n^{\circ}$ | Référence | Test | $n^{\circ}$ | Référence | Test |
|-------------|-----------|------|-------------|-----------|------|
| 1           | 9,2       | 9,5  | 7           | 10,0      | 10,1 |
| 2           | 10,0      | 9,0  | 8           | 10,3      | 9,3  |
| 3           | 9,0       | 8,8  | 9           | 10,2      | 9,0  |
| 4           | 9,4       | 9,5  | 10          | 10,2      | 9,7  |
| 5           | 10,1      | 9,1  | 11          | 9,8       | 9,1  |
| 6           | 9,5       | 10,0 | 12          | 10,1      | 9,3  |

Y a-t-il une différence significative entre les résultats des deux méthodes?



# Analyse de la variance (ANOVA)

On considère  $k$  échantillon issus de lois normales et de tailles respectives  $n_1, \dots, n_k$ . On suppose qu'un facteur  $A$  de niveaux  $A_1, \dots, A_k$ , influe sur les moyennes mais pas sur les variances. En supposant que pour tout  $i = 1, \dots, k$ , on a  $\sigma_i^2 = \sigma^2$ , on désire tester

$H_0 : \mu = \mu_1 = \dots = \mu_k$  contre  $H_1 : \exists i, j = 1, \dots, k$  tel que  $\mu_i \neq \mu_j$ . Pour cela, on construit le tableau

| $A_1$       | $A_2$       | $\dots$ | $A_i$       | $\dots$ | $A_k$       |
|-------------|-------------|---------|-------------|---------|-------------|
| $x_{11}$    | $x_{21}$    | $\dots$ | $x_{i1}$    | $\dots$ | $x_{k1}$    |
| $x_{12}$    | $x_{22}$    | $\dots$ | $x_{i2}$    | $\dots$ | $x_{k2}$    |
| $\vdots$    | $\vdots$    |         | $\vdots$    |         | $\vdots$    |
| $x_{1n_1}$  | $x_{2n_2}$  | $\dots$ | $x_{in_i}$  | $\dots$ | $x_{kn_k}$  |
| $\bar{x}_1$ | $\bar{x}_2$ | $\dots$ | $\bar{x}_i$ | $\dots$ | $\bar{x}_k$ |

# Analyse de la variance (ANOVA)

Sachant que  $\bar{X}_i = \frac{1}{n_i} \sum_{j=1}^{n_i} x_{ij}$  et que  $\bar{X} = \frac{1}{n} \sum_{i=1}^k \sum_{j=1}^{n_i} x_{ij}$  et en posant  $X_{ij} - \bar{X} = (X_{ij} - \bar{X}_i) + (\bar{X}_i - \bar{X})$  on obtient l'équation de l'analyse de la variance

$$\frac{1}{n} \sum_{i=1}^k \sum_{j=1}^{n_i} (X_{ij} - \bar{X})^2 = \frac{1}{n} \sum_{i=1}^k \sum_{j=1}^{n_i} (X_{ij} - \bar{X}_i)^2 + \frac{1}{n} \sum_{i=1}^k n_i (\bar{X}_i - \bar{X})^2.$$

Alors, la variance totale est égale à

$$S^2 = S_R^2 + S_A^2, \text{ formule d'analyse de variance}$$

$S_R^2 = \frac{1}{n} \sum_{i=1}^k \sum_{j=1}^{n_i} (X_{ij} - \bar{X}_i)^2 = \frac{1}{n} \sum_{i=1}^k n_i \frac{1}{n_i} \sum_{j=1}^{n_i} (X_{ij} - \bar{X}_i)^2 = \frac{1}{n} \sum_{i=1}^k n_i S_i^2$  est la moyenne des variances à l'intérieur de chaque échantillon appelée variance résiduelle.

$S_A^2 = \frac{1}{n} \sum_{i=1}^k n_i (\bar{X}_i - \bar{X})^2$  est la variance des moyennes (variance due au facteur).

# Analyse de la variance (ANOVA)

Sachant que

$$\frac{n_i S_i^2}{\sigma^2} \rightsquigarrow \chi^2(n_i - 1) \text{ et } \frac{n S_R^2}{\sigma^2} = \sum_{i=1}^k \frac{n_i S_i^2}{\sigma^2} \rightsquigarrow \chi^2\left(\sum_{i=1}^k (n_i - 1) = n - k\right).$$

Sous  $H_0$

$$\frac{n S^2}{\sigma^2} \rightsquigarrow \chi^2(n - 1) \text{ et } \frac{n S_A^2}{\sigma^2} \rightsquigarrow \chi^2(k - 1),$$

alors

$$\frac{\frac{S_A^2}{k-1}}{\frac{S_R^2}{n-k}} \rightsquigarrow \mathcal{F}(k-1, n-k)$$

au seuil  $\alpha$  on rejette  $H_0$  si  $F_c = \frac{s_A^2}{k-1} \frac{n-k}{s^2} \geq F_{k-1, n-k}(\alpha)$ , dans ce cas le carré moyen résiduel  $\frac{n S_R^2}{n-k}$  est un estimateur sans biais de  $\sigma^2$ .



# Test de Bartlett

Dans l'analyse de la variance les populations sont supposées de même variance. Il faut normalement tester cette hypothèse i.e.

Tester  $H_0 : \sigma_1^2 = \dots = \sigma_k^2$  contre  $H_1 : \exists i, j = 1, \dots, k$  tel que  $\sigma_i^2 \neq \sigma_j^2$ .

Avec les mêmes notations que précédemment on a sous  $H_0$  la v.a.

$$B = \frac{1}{\lambda} \left[ (n - k) \ln S_R^2 - \sum_{i=1}^k (n_i - 1) \ln S_i^2 \right] \rightsquigarrow \chi^2(k - 1)$$

$$\text{avec } \lambda = 1 + \frac{1}{3(k - 1)} \left[ \left( \sum_{i=1}^k \frac{1}{n_i - 1} \right) - \frac{1}{n - k} \right].$$

On calcule la valeur  $b$  prise par la v.a.  $B$ .

Si  $b \geq \chi_{\alpha}^2(k - 1)$  on rejette l'hypothèse  $H_0$ .

# Test de Kruskal et Wallis

Equivalent non-paramétrique de l'ANOVA à un facteur.

**Procédure :** On classe toutes les valeurs des  $k$  échantillons par ordre croissant, en reppérant de quel échantillon provient chacune des mesures. Ensuite on détermine le rang et en cas d'ex-aequo, on fait comme pour le test de spearman. On note  $r_i$ , la somme des rangs des valeurs de l'échantillon  $E_i$ , puis on calcule

$$h = \frac{12}{n(n+1)} \left( \sum_{i=1}^k \frac{r_i^2}{n_i} \right) - 3(n+1).$$

**Décision :** Soit  $H$  la v.a. qui prend la valeur  $h$ .

- Si  $\forall i, n_i > 5$ , alors sous  $H_0$ ,  $H \rightsquigarrow \chi^2(k-1)$ . Dans la table de Khi2, on lit la valeur  $\chi_\alpha^2$  et on rejette  $H_0$  si  $h \geq \chi_\alpha^2$ .
- Si les  $n_i \leq 5$ , on a des tables de Kruskal-Wallis qui donnent la valeur  $h_\alpha$  telle que  $\mathbb{P}(h \geq h_\alpha)$ . On rejette  $H_0$  si  $h \geq h_\alpha$ .

## Exemple

A la mi-mai, 32 ruches élevées dans des conditions identiques et donc de force très comparables, sont réparties en 4 lots de 8 ruches chacun sur les pâturages d'un même versant de montagne mais à des altitudes différentes. La production de miel récoltée à la fin juillet, exprimée en kg, se distribue comme suit :

|                   |    |    |    |    |    |    |    |    |
|-------------------|----|----|----|----|----|----|----|----|
| Rucher 1 (1480 m) | 12 | 17 | 13 | 15 | 10 | 15 | 11 | 14 |
| Rucher 2 (1700 m) | 11 | 15 | 14 | 19 | 16 | 12 | 10 | 8  |
| Rucher 3 (1850 m) | 12 | 7  | 13 | 14 | 11 | 10 | 14 | 9  |
| Rucher 4 (1960 m) | 8  | 12 | 14 | 9  | 11 | 11 | 6  | 11 |

Commentez l'effet global de l'altitude sur la production de miel

- 1 Dans le cas où les populations sont supposées gaussiennes.
- 2 Dans le cas où les populations sont inconnues.