

## TESTS D'HYPOTHESE

### 1 Etude sur un seul caractère.

#### 1.1 Test de conformité à une loi

On considère une v.a.  $X$  et on désire tester l'ajustement de sa loi notée  $\mathcal{L}$  à une loi connue  $\mathcal{L}_0$ . On va alors tester :  $H_0 : \mathcal{L} = \mathcal{L}_0$  contre  $H_1 : \mathcal{L} \neq \mathcal{L}_0$ .

1. **Test du Khi2** : On a  $n$  observations de la variable  $X$  partagées en  $k$  classes. Soit  $O_i$  l'effectif observé de la classe  $i$ . On calcul l'effectif théorique par  $C_i = n \cdot \mathbb{P}(X \in \text{classe}_i / X \rightsquigarrow \mathcal{L}_0)$ .

On calcule la valeur de la variable aléatoire  $K = \sum_{i=1}^k \frac{(O_i - C_i)^2}{C_i} \rightsquigarrow \chi^2(\nu = k - 1 - r)$ , avec  $r$  le nombre de paramètres de la loi  $\mathcal{L}_0$  qu'on a du estimer et on rejette  $H_0$  si  $\chi_c^2 > \chi_\alpha^2$ .

2. **Test de Kolmogorov** : La statistique de Kolmogorov-Smirnov est  $D_n = \sup_{x \in \mathbb{R}} |F_n(x) - F(x)|$ . Si  $D_n > \frac{c}{\sqrt{n}}$ , on rejette  $H_0$ ,  $c$  étant une valeur tabulée dépendant de  $n$  et de  $\alpha$ .

#### 1.2 Tests de conformité

##### 1.2.1 Population gaussienne ou taille d'échantillon $n > 30$ .

| Test de conformité d'une                        | Hypothèses                                                    | Statistique                                                                          | Intervalle d'acceptation                                        |
|-------------------------------------------------|---------------------------------------------------------------|--------------------------------------------------------------------------------------|-----------------------------------------------------------------|
| Moyenne avec<br>variance $\sigma^2$<br>connue   | $H_0 : \mu = \mu_0$ vs $H_1 : \mu \neq \mu_0$                 | $Z = \frac{\bar{X} - \mu_0}{\sigma_0 / \sqrt{n}} \rightsquigarrow \mathcal{N}(0, 1)$ | $I_\alpha = [-z_{1-\frac{\alpha}{2}}, +z_{1-\frac{\alpha}{2}}]$ |
|                                                 | $H_0 : \mu \leq \mu_0$ vs $H_1 : \mu > \mu_0$                 |                                                                                      | $I_\alpha = ]-\infty, z_{1-\alpha}]$                            |
|                                                 | $H_0 : \mu \geq \mu_0$ vs $H_1 : \mu < \mu_0$                 |                                                                                      | $I_\alpha = [-z_{1-\alpha}, +\infty[$                           |
| Moyenne avec<br>variance $\sigma^2$<br>inconnue | $H_0 : \mu = \mu_0$ vs $H_1 : \mu \neq \mu_0$                 | $T = \frac{\bar{X} - \mu_0}{S / \sqrt{n-1}} \rightsquigarrow \mathcal{T}_{n-1}$      | $I_\alpha = [-t_{1-\frac{\alpha}{2}}, +t_{1-\frac{\alpha}{2}}]$ |
|                                                 | $H_0 : \mu \leq \mu_0$ vs $H_1 : \mu > \mu_0$                 |                                                                                      | $I_\alpha = ]-\infty, t_{1-\alpha}]$                            |
|                                                 | $H_0 : \mu \geq \mu_0$ vs $H_1 : \mu < \mu_0$                 |                                                                                      | $I_\alpha = [-t_{1-\alpha}, +\infty[$                           |
| Proportion                                      | $H_0 : p = p_0$ vs $H_1 : p \neq p_0$                         | $Z = \frac{\sqrt{n}(\bar{X} - p)}{\sqrt{p(1-p)}} \rightsquigarrow \mathcal{N}(0, 1)$ | $I_\alpha = [-z_{1-\frac{\alpha}{2}}, +z_{1-\frac{\alpha}{2}}]$ |
|                                                 | $H_0 : p \leq p_0$ vs $H_1 : p > p_0$                         |                                                                                      | $I_\alpha = ]-\infty, z_{1-\alpha}]$                            |
|                                                 | $H_0 : p \geq p_0$ vs $H_1 : p < p_0$                         |                                                                                      | $I_\alpha = [-z_{1-\alpha}, +\infty[$                           |
| Variance                                        | $H_0 : \sigma = \sigma_0$ contre $H_1 : \sigma \neq \sigma_0$ | $K = \frac{nS^2}{\sigma_0^2} \rightsquigarrow \chi_{n-1}^2$                          | $I_\alpha = [k_{\frac{\alpha}{2}}, k_{1-\frac{\alpha}{2}}]$     |
|                                                 | $H_0 : \sigma \leq \sigma_0$ contre $H_1 : \sigma > \sigma_0$ |                                                                                      | $I_\alpha = [0, k_{1-\alpha}]$                                  |
|                                                 | $H_0 : \sigma \geq \sigma_0$ contre $H_1 : \sigma < \sigma_0$ |                                                                                      | $I_\alpha = [k_{1-\alpha}, +\infty[$                            |

## 1.3 Tests de comparaison

### 1.3.1 Population gaussienne ou tailles d'échantillons $n_1 > 30$ et $n_2 > 30$ .

| Test de comparaison de 2                             | Hypothèses                                                    | Statistique                                                                                                                                                                                 | Intervalle d'acceptation                                        |
|------------------------------------------------------|---------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------|
| Moyennes avec<br>variance $\sigma^2$<br><br>connue   | $H_0 : \mu_1 = \mu_2$ vs $H_1 : \mu_1 \neq \mu_2$             | $Z = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \rightsquigarrow \mathcal{N}(0, 1)$                                                               | $I_\alpha = [-z_{1-\frac{\alpha}{2}}, +z_{1-\frac{\alpha}{2}}]$ |
|                                                      | $H_0 : \mu_1 \leq \mu_2$ vs $H_1 : \mu_1 > \mu_2$             |                                                                                                                                                                                             | $I_\alpha = ]-\infty, z_{1-\alpha}]$                            |
|                                                      | $H_0 : \mu_1 \geq \mu_2$ vs $H_1 : \mu_1 < \mu_2$             |                                                                                                                                                                                             | $I_\alpha = [-z_{1-\alpha}, +\infty[$                           |
| Moyennes avec<br>variance $\sigma^2$<br><br>inconnue | $H_0 : \mu_1 = \mu_2$ vs $H_1 : \mu_1 \neq \mu_2$             | $T = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\left(\frac{1}{n_1} + \frac{1}{n_2}\right) \left(\frac{n_1 S_1^2 + n_2 S_2^2}{n_1 + n_2 - 2}\right)}} \rightsquigarrow \mathcal{T}_{n_1 + n_2 - 2}$ | $I_\alpha = [-t_{1-\frac{\alpha}{2}}, +t_{1-\frac{\alpha}{2}}]$ |
|                                                      | $H_0 : \mu_1 \leq \mu_2$ vs $H_1 : \mu_1 > \mu_2$             |                                                                                                                                                                                             | $I_\alpha = ]-\infty, t_{1-\alpha}]$                            |
|                                                      | $H_0 : \mu_1 \geq \mu_2$ vs $H_1 : \mu_1 < \mu_2$             |                                                                                                                                                                                             | $I_\alpha = [-t_{1-\alpha}, +\infty[$                           |
| Proportions                                          | $H_0 : p_1 = p_2$ vs $H_1 : p_1 \neq p_2$                     | $Z = \frac{f_1 - f_2}{\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}} \rightsquigarrow \mathcal{N}(0, 1)$<br>avec $\hat{p} = \frac{n_1 f_1 + n_2 f_2}{n_1 + n_2}$                                      | $I_\alpha = [-z_{1-\frac{\alpha}{2}}, +z_{1-\frac{\alpha}{2}}]$ |
|                                                      | $H_0 : p_1 \leq p_2$ vs $H_1 : p_1 > p_2$                     |                                                                                                                                                                                             | $I_\alpha = ]-\infty, z_{1-\alpha}]$                            |
|                                                      | $H_0 : p_1 \geq p_2$ vs $H_1 : p_1 < p_2$                     |                                                                                                                                                                                             | $I_\alpha = [-z_{1-\alpha}, +\infty[$                           |
| Variances                                            | $H_0 : \sigma_1 = \sigma_2$ vs $H_1 : \sigma_1 \neq \sigma_2$ | $F = \frac{n_1 S_1^2}{n_2 S_2^2} \rightsquigarrow \mathcal{F}(n_1 - 1, n_2 - 1)$                                                                                                            | $I_\alpha = [f_{\frac{\alpha}{2}}, f_{1-\frac{\alpha}{2}}]$     |
|                                                      | $H_0 : \sigma_1 \leq \sigma_2$ vs $H_1 : \sigma_1 > \sigma_2$ |                                                                                                                                                                                             | $I_\alpha = [0, f_{1-\alpha}]$                                  |
|                                                      | $H_0 : \sigma_1 \geq \sigma_2$ vs $H_1 : \sigma_1 < \sigma_2$ |                                                                                                                                                                                             | $I_\alpha = [f_{1-\alpha}, +\infty[$                            |

### 1.3.2 Population inconnue et tailles d'échantillons $n_1 > 30$ ou $n_2 > 30$ .

#### 1. Test de Mann et Whitney (deux échantillons indépendants de tailles différentes)

Soit  $U$  la variable aléatoire de valeur  $u = \min\{u_1, u_2\}$ .

- Pour  $n_1$  et  $n_2$  quelconques, on lit dans les tables du test de Mann et Whitney le nombre  $m_\alpha$  tel que, sous  $H_0$ ,  $\mathbb{P}(U \leq m_\alpha) = \alpha$  et  $I_\alpha = ]m_\alpha, +\infty[$
- Si  $n_1$  et  $n_2$  sont assez grands (20 en général), sous  $H_0$ ,  $U$  suit approximativement la loi  $\mathcal{N}(\mu, \sigma)$  avec  $\mu = \frac{n_1 n_2}{2}$  et  $\sigma = \sqrt{\frac{n_1 n_2 (n_1 + n_2 + 1)}{12}}$ .

On lit  $u_\alpha$  dans la table de l'écart réduit de la loi normale tel que  $\mathbb{P}(|U| \geq u_\alpha) = \alpha$ , on calcule  $z_\alpha = \frac{u_\alpha - \mu}{\sigma}$  et  $I_\alpha \in ]-z_\alpha, z_\alpha[$ .

#### 2. Test de Wilcoxon (deux échantillons appariés i.e. de même taille)

Soit  $W$  la variable aléatoire de valeur  $w = \min \{w_+, w_-\}$ .

- Si  $N \leq 25$ , on lit dans les tables du test de Wilcoxon le nombre  $w_\alpha$  tel que, sous  $H_0$ ,  $\mathbb{P}(U \geq w_\alpha) = \alpha$ . On rejette  $H_0$  au risque d'erreur  $\alpha$  si  $w \geq w_\alpha$ .
- Si  $N > 25$ , sous  $H_0$ ,  $W$  suit approximativement la  $\mathcal{N}(\mu, \sigma)$  avec  $\mu = \frac{N(N+1)}{2}$  et  $\sigma = \sqrt{\frac{N(N+1)(2N+1)}{24}}$ , on calcule  $z_\alpha = \frac{u_\alpha - \mu}{\sigma}$  et  $I_\alpha \in ]-z_\alpha, z_\alpha[$ .

### 1.3.3 On dispose de $k$ échantillons indépendants.

On imera comparer simultanément les moyennes

- Populations gaussiennes de même variance : **ANOVA** à un facteur et on vérifie l'égalité des variances par le **test de Bartlett** pour cela on calcule

$$B = \frac{1}{\lambda} \left[ (n-k) \ln S_R^2 - \sum_{i=1}^k (n_i - 1) \ln S_i^2 \right] \rightsquigarrow \chi^2(k-1)$$

$$\text{avec } \lambda = 1 + \frac{1}{3(k-1)} \left[ \left( \sum_{i=1}^k \frac{1}{n_i - 1} \right) - \frac{1}{n-k} \right].$$

On calcule la valeur  $b$  prise par la v.a.  $B$ . Si  $b \geq \chi_\alpha^2(k-1)$  on rejette l'hypothèse  $H_0$ .

Pour l'**ANOVA** on calcule la valeur de

$$F = \frac{\frac{S_F^2}{k-1}}{\frac{S_R^2}{n-k}} \rightsquigarrow \mathcal{F}(k-1, n-k)$$

au seuil  $\alpha$  on rejette  $H_0$  si  $F_c = \frac{s_F^2}{k-1} \frac{n-k}{s_R^2} \geq F_{k-1, n-k}(\alpha)$ , avec  $s_F^2$  est la variance factorielle et  $S_R^2$  est la variance résiduelle.

- Populations inconnues: **Test de Kruskal et Wallis**. On calcule le nombre

$$h = \frac{12}{n(n+1)} \left( \sum_{i=1}^k \frac{r_i^2}{n_i} \right) - 3(n+1).$$

Soit  $H$  la v.a. qui prend la valeur  $h$ .

- Si  $\forall i, n_i > 5$ , alors sous  $H_0$ ,  $H \rightsquigarrow \chi^2(k-1)$ . Dans la table de Khi2, on lit la valeur  $\chi_\alpha^2$  et on rejette  $H_0$  si  $h \geq \chi_\alpha^2$ .
- Si les  $n_i \leq 5$ , on a des tables de Kruskal-Wallis qui donnent la valeur  $h_\alpha$  telle que  $\mathbb{P}(h \geq h_\alpha)$ . On rejette  $H_0$  si  $h \geq h_\alpha$ .

## 2 Etude simultanée de deux caractères

### 2.1 Etude de l'indépendance

1. les deux caractères sont qualitatifs : On calcule la valeur de la variable

$$\sum_{i,j} \frac{(n_{ij} - C_{ij})^2}{C_{ij}} = \chi_c^2 \rightsquigarrow \chi^2(\nu) \text{ où } \nu = (l-1) \times (k-1).$$

On cherche la valeur critique  $\chi_\alpha^2$  dans la table de la loi du *Khi2* à  $\nu$  degrés de liberté. Décision : si  $\chi_c^2 < \chi_\alpha^2$ , on accepte l'hypothèse  $H_0$ .

2. Les deux caractères sont quantitatifs

- Populations gaussiennes: On calcule la valeur de la variable  $T = \frac{R\sqrt{n-2}}{\sqrt{1-R^2}} \rightsquigarrow \mathcal{T}(\nu = n-2)$ . Puis on déterminera  $t_\alpha$  ou  $t_{\frac{\alpha}{2}}$  de la table de la loi de students à  $\nu = n-2$  degrés de liberté et on adoptera la règle de décision suivante :

- Si  $H_1 : \rho \neq 0$  : rejet de  $H_0$  au risque  $\alpha$  si  $t_c \notin ]-t_{\frac{\alpha}{2}}; t_{\frac{\alpha}{2}}[$  ;
- Si  $H_1 : \rho > 0$  : rejet de  $H_0$  au risque  $\alpha$  si  $t_c > t_\alpha$  ;
- Si  $H_1 : \rho < 0$  : rejet de  $H_0$  au risque  $\alpha$  si  $t_c < -t_\alpha$ .

1. - Populations de lois inconnues: **Test de Spearman** on calcule  $r_S = 1 - \frac{6 \sum (x'_i - y'_i)^2}{n(n^2-1)}$  à partir des couples des rangs.

- Si  $n \leq 13$ . Pour un risque  $\alpha$  on détermine la valeur de  $r_\alpha$  telle  $P(|R_S| > r_\alpha) = \alpha$  lue dans la table de Spearman. Si  $|r_S| > r_\alpha$  on rejette  $H_0$  avec un risque  $\alpha$  de se tromper.
- Si  $n > 13$ . Dans ce cas si  $H_0$  est vraie, la statistique  $T = \frac{R_S\sqrt{n-2}}{\sqrt{1-R_s^2}}$  suit approximativement la loi de Student à  $n-2$  ddl. La décision se fera à l'aide la table du coefficient de corrélation linéaire qui donne la valeur de  $r_\alpha$  telle que  $P(|R_S| > r_\alpha) = \alpha$ .

3. Un caractère qualitatif et l'autre est quantitatif:

- Populations gaussiennes: **ANOVA** à un facteur
- Populations de lois inconnues: **Test de Kruskal et Wallis**.