Natural Language Processing

Prof. Ahmed Guessoum
The National Higher School of AI

Chapter 1

Introduction

The Most Beneficent الرحمن،

علم القرآن،

Has taught (you mankind) the Qur'an

خلق الإنسان، He created man

علمه البيان He taught him

eloquent speech (Qur’an, 55:1-3)

(Eloquence) البيان

- Language (Expressiveness)
- Thinking and Reasoning
- Communication (skill)
- Effectiveness in conveying some content

➔ Be(ing)

NLP

- Goal of NLP: get computers to perform useful tasks involving human language, e.g.:
  - enabling human-machine communication
  - improving human-human communication
  - doing useful processing of text or speech, etc.
- Conversational agents (e.g. HAL 9000 computer in Stanley Kubrick's film 2001*: A Space Odyssey; Apple SIRI, Amazon Alexa, …*)
  - Analyse language input (**Automatic Speech Recognition** and **N.L. Understanding**)
  - Generate language output (**NL generation** and **Speech Synthesis**).
- Machine Translation

NLP (cont.)

- Web-based Question Answering
  - **Definition** questions
  - **Factoid** questions.
  - More complex questions (**How**, **Why**):
    - information embedded in other text on a Web page,
    - doing **inference** (drawing conclusions based on known facts),
    - synthesizing and summarizing information from multiple sources or web pages.
- Modern understanding systems, including **Info. Extraction**, **Word Sense Disambiguation**
- The chapter presents the kind of knowledge necessary for these tasks (and others like **spell correction**, **grammar checking**, text generation, …) and (throughout the course) the needed mathematical models.

NLP

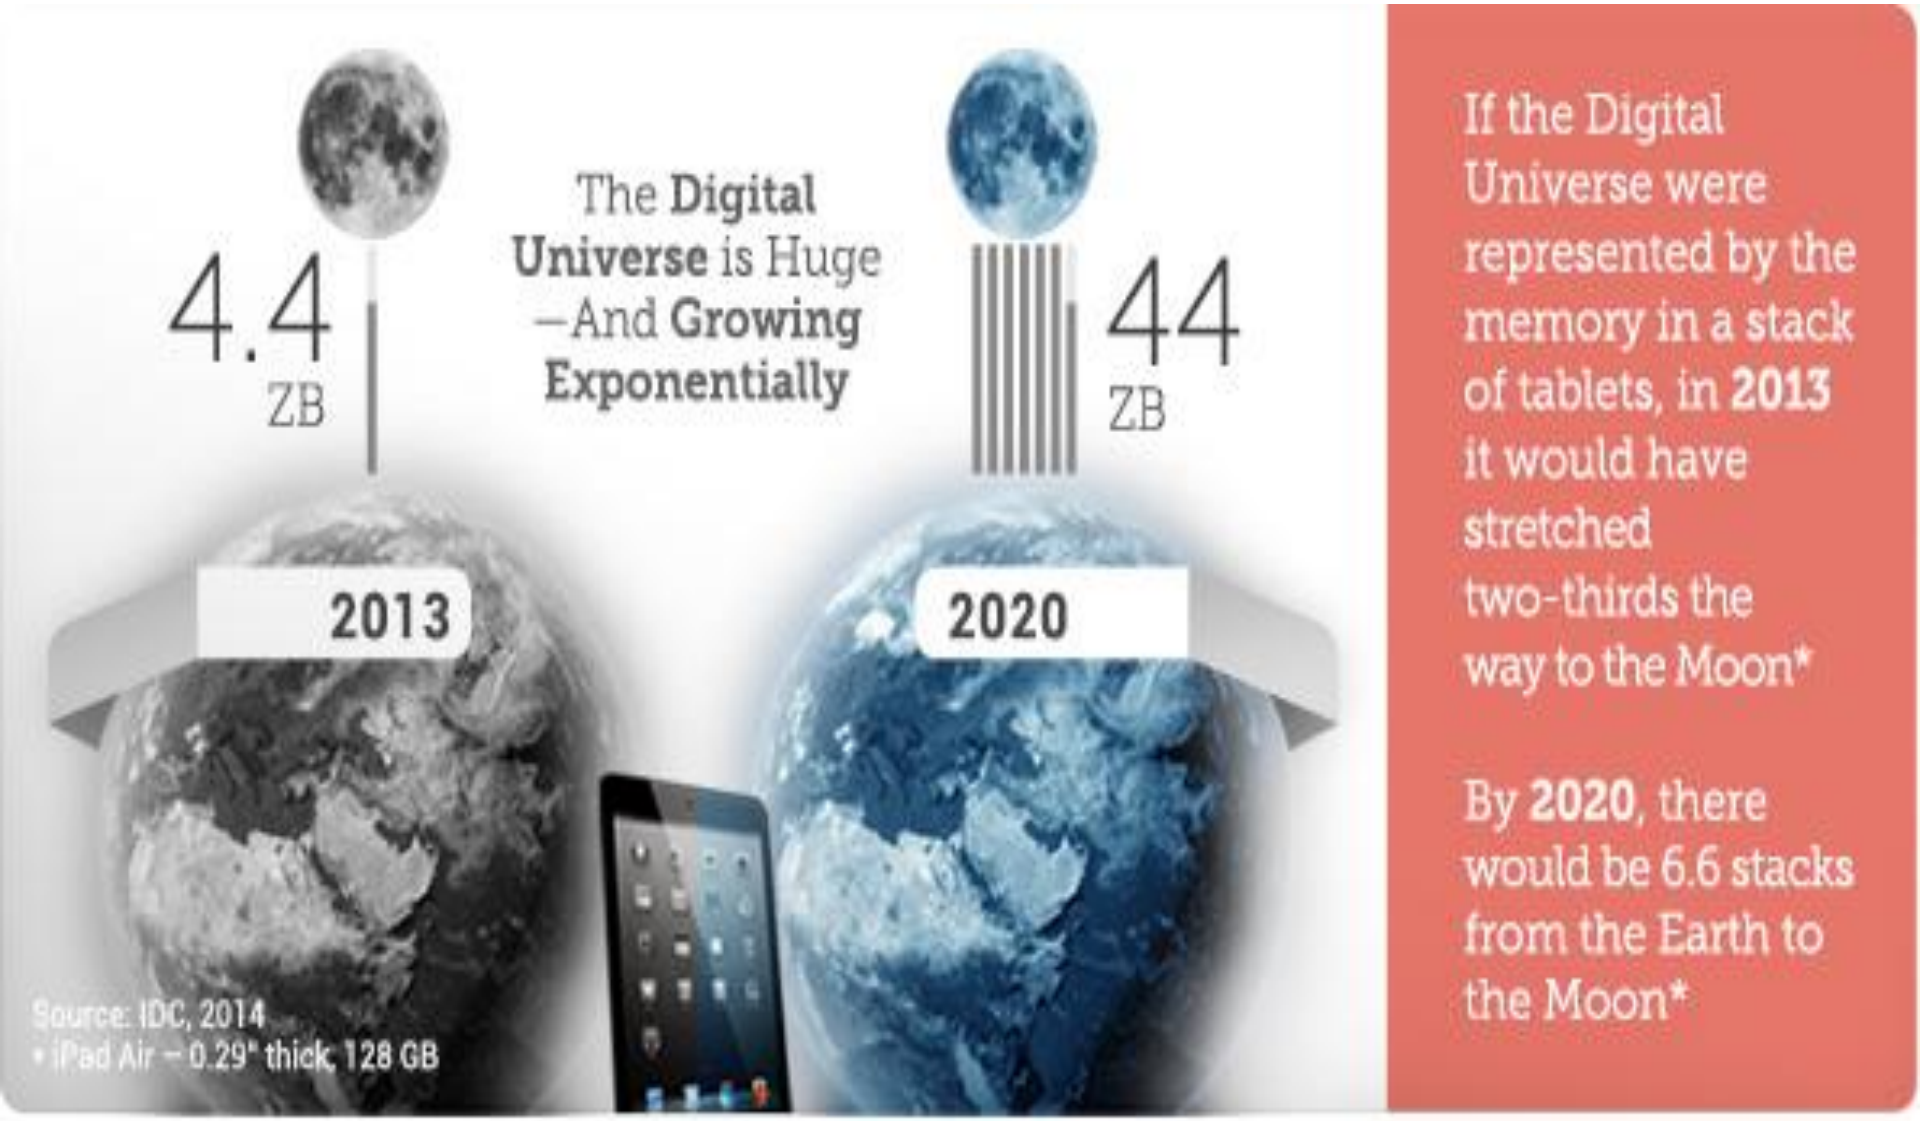
Questions:

1. What is required for computers to learn useful and interesting tasks that use human language?

2. What can we learn from this effort regarding human language processing?

Is NLP Important?

The Digital Universe (7th EMC Digital Universe study, IDC, 2014)



Is NLP Important?

- A huge amount of knowledge now available electronically in the form of NL texts (online journals, Wikipedia, etc.)
  - global data reached 181 zettabytes (181×10^{21} Bytes) in 2025 and is projected to reach 394 zettabytes by 2028
- Conversational agents now an important form of human-machine communication and work: think of **chatbots**, **generative AI**
- Much human-human communication is facilitated by machines: e.g. **MT** and **Speech-to-speech MT**, **text summarisation**, etc.

"Breaking Down The Numbers: How Much Data Does The World Create Daily in 2024?" (Edge Delta)

- **Facebook** produces ~ 4,000 TB daily, ranking #1 in "most visited sites globally in 2023".
- **X (Twitter)**: around 500 million tweets daily, which amounts to 560 GB of data.
- 2024: **TikTok** videos produce ~ 7.35 TB of data/day
- **YouTube** hosted over 720,000 hours of videos daily in 2023, which is equivalent to about 4.3 PB of data.
- **Google** processes around 3.5 billion searches daily, amounting to 20 PB**.**
- In **2023**, the average **internet user** created about 1.7 MB of data per second, i.e. 146.88 GB daily.

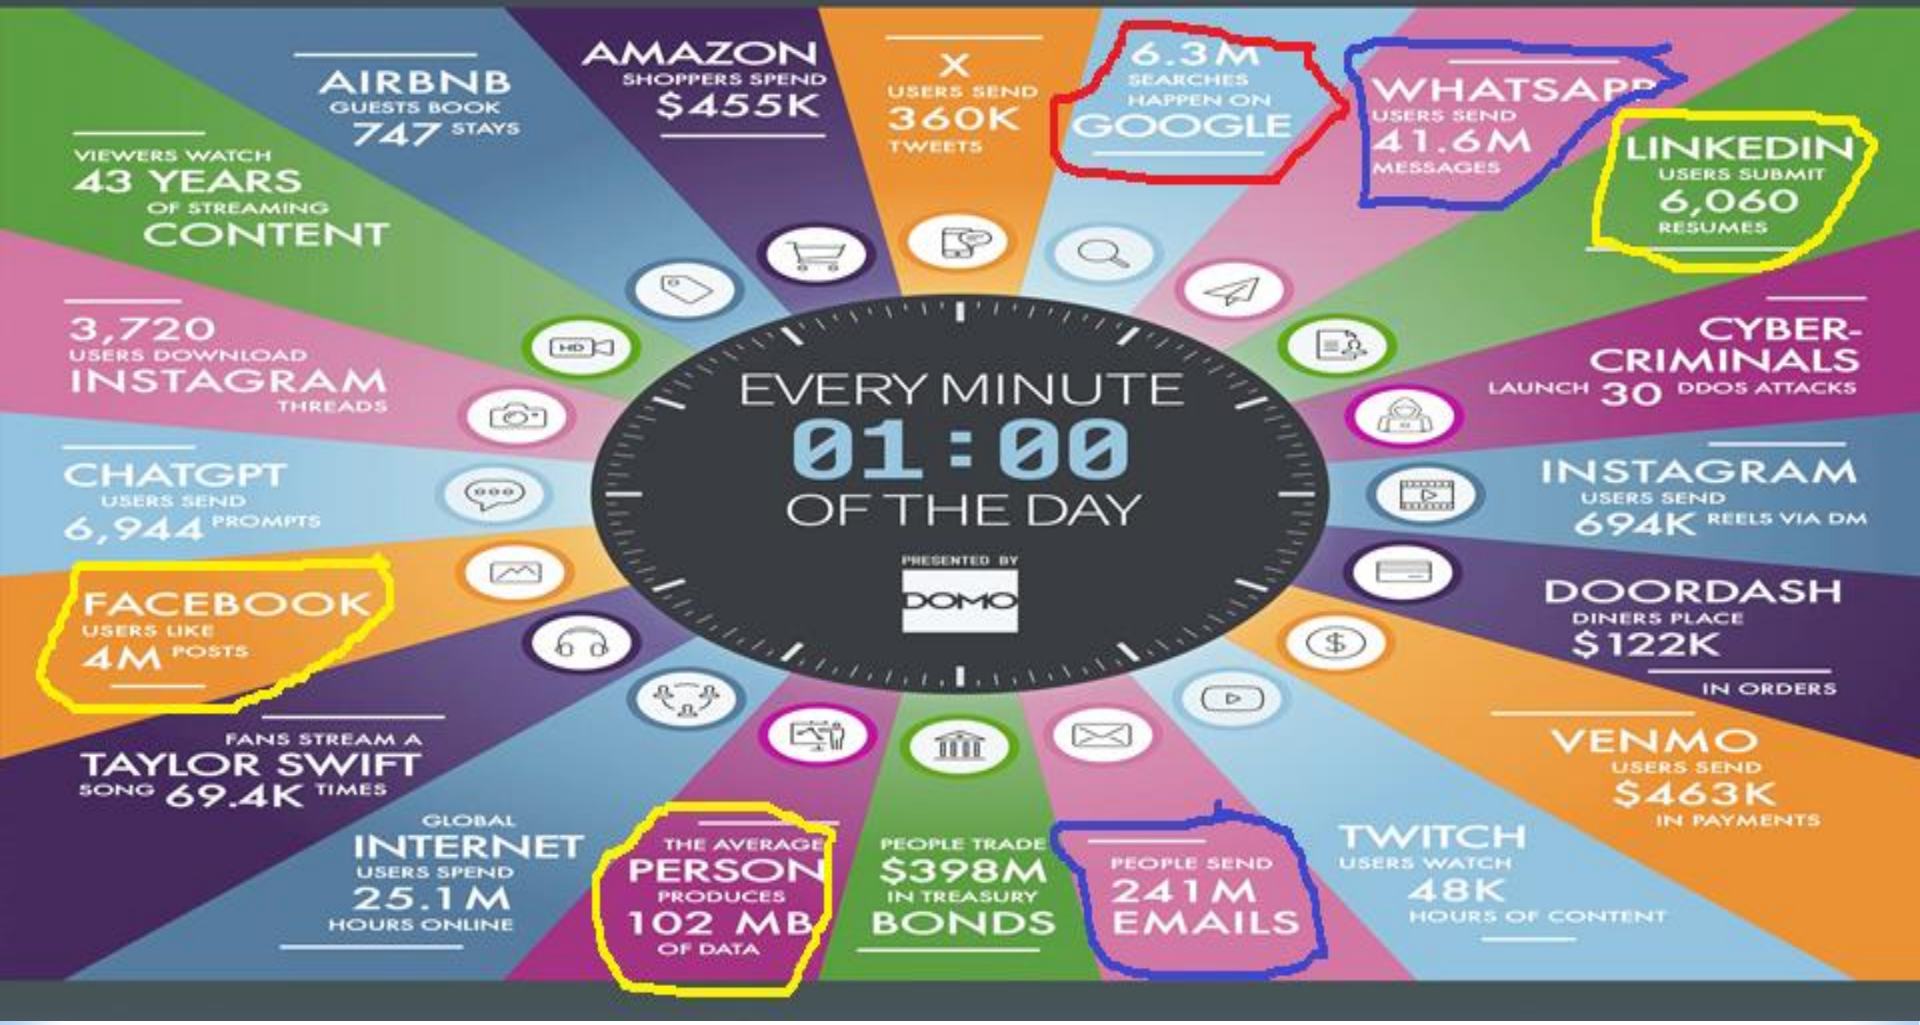
An Information Tsunami!

- 5.65 billion users on the internet (as of July 2025) https://datareportal.com/global-digital-overview?utm_source=chatgpt.com
- One person downloading the entire 2025 Global Datasphere at an average of 25 Mb/s would take 1.8 billion years OR, for the world population, 81 days (working 24x7)
- Using big data, Netflix saves $1 billion per year on customer retention (195.15 M customers as of 3rd Quarter 2020) on its 100 million customers (*https://insidebigdata.com/2018/01/20/netflix-uses-big-data-drive-success/*)

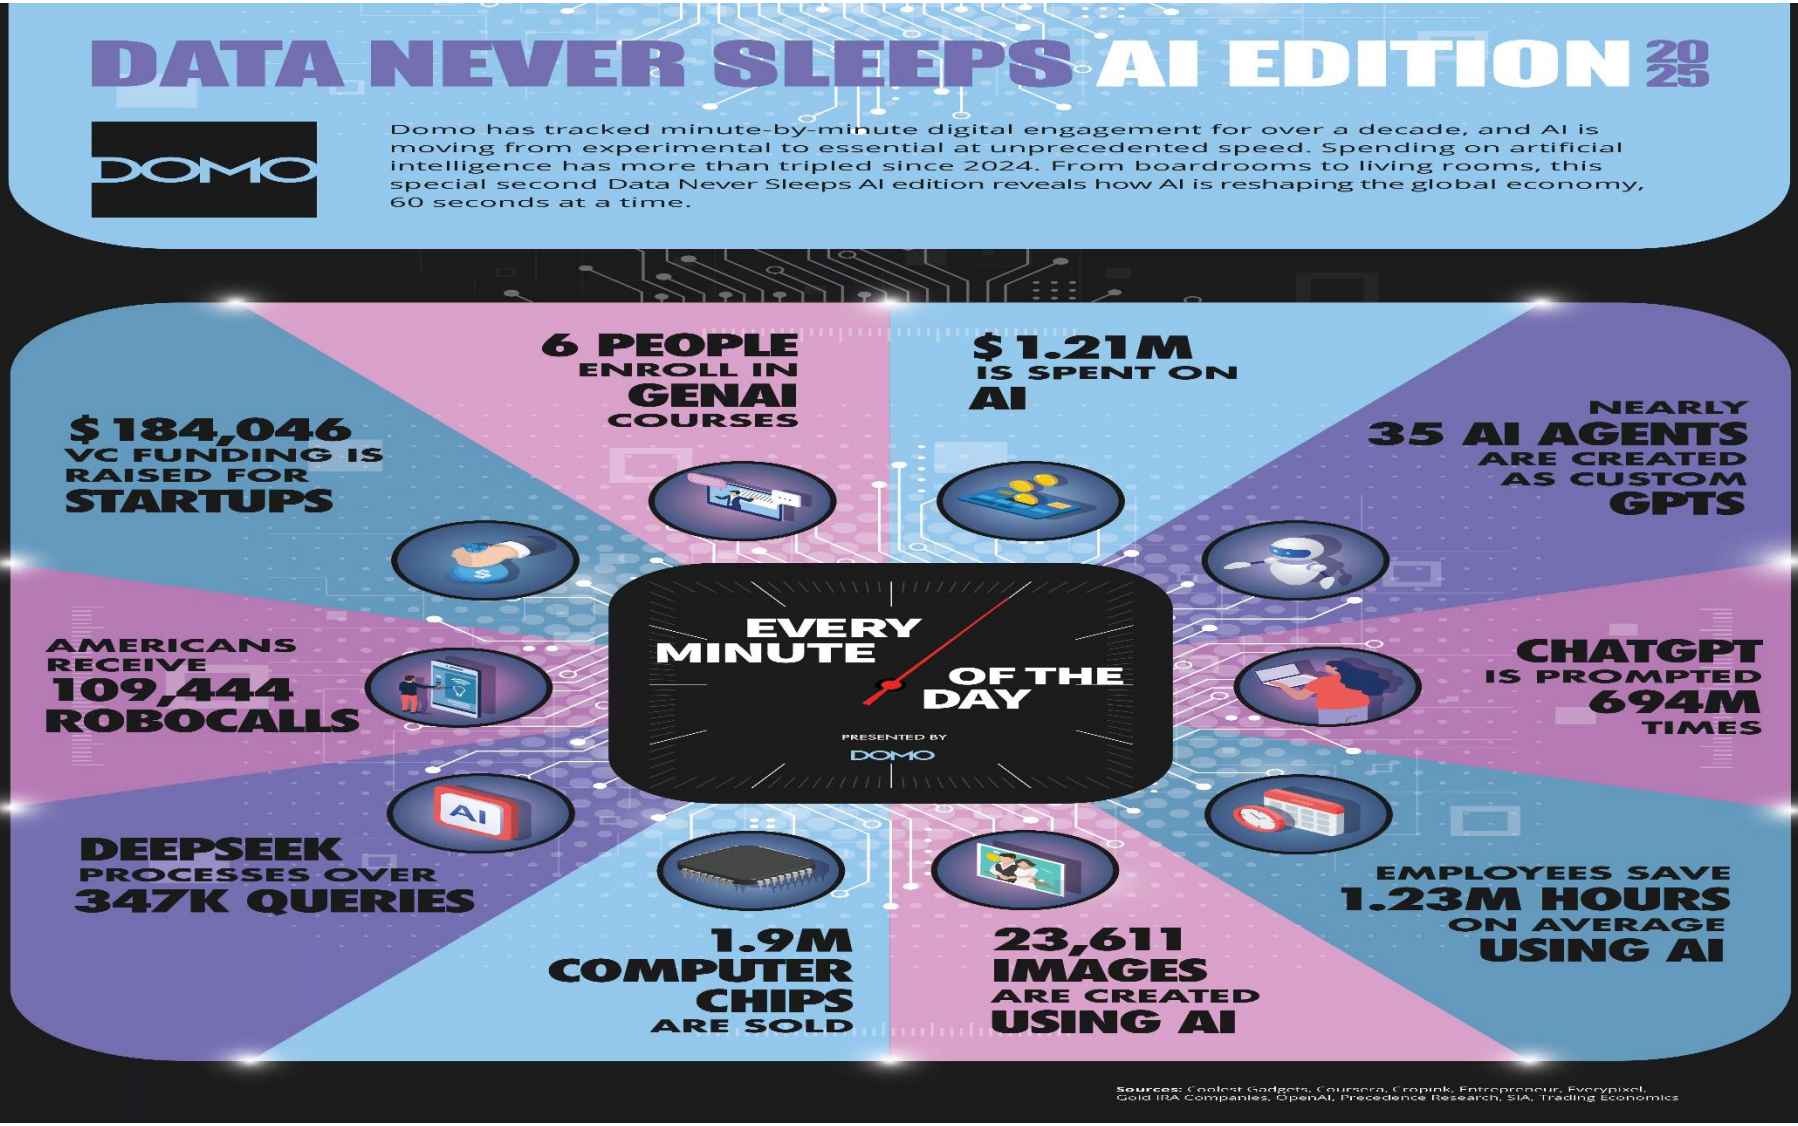
Data Never Sleeps 11.0

Domo has been keeping tabs on the world's data usage—in a minute—for over a decade now. What the numbers consistently show is that how we use data is always evolving—and that data isn't slowing down. We're also seeing some big changes. The rise of Artificial Intelligence (AI) is reshaping the way we communicate, work, and create. Digital payments continue to replace traditional transactions. Taylor Swift streams in countless headphones. And a rash of cybercrime grows alongside these digital experiences.

In Domo's 11th edition of Data Never Sleeps, we take the pulse of our digital age, where every click, swipe, and stream fuels an ever-expanding digital universe. These are not just numbers; they are the heartbeat of a world where data reigns supreme.

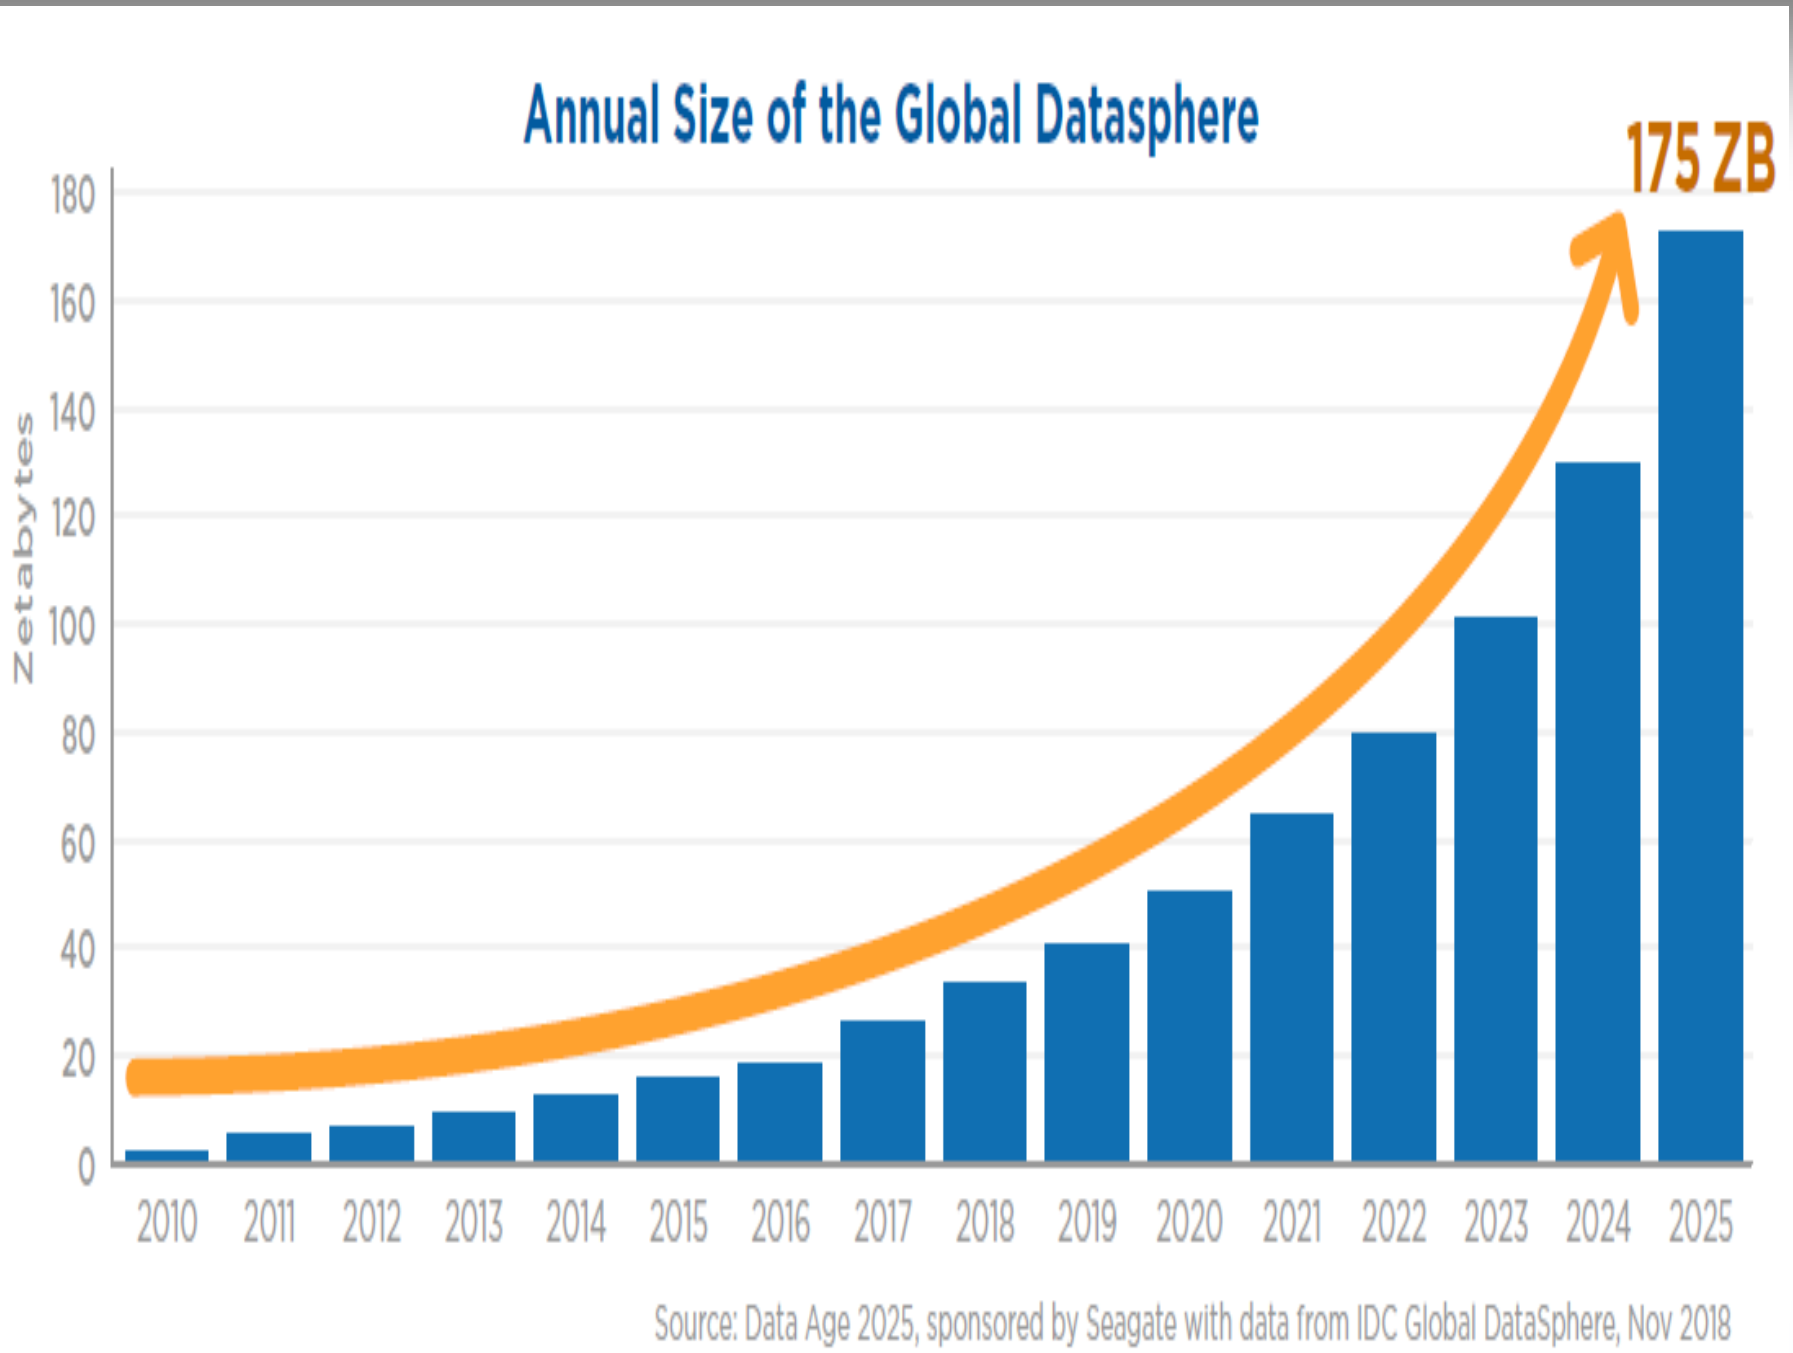


"Data Never Sleeps: AI Edition" by Domo Aug. 2025

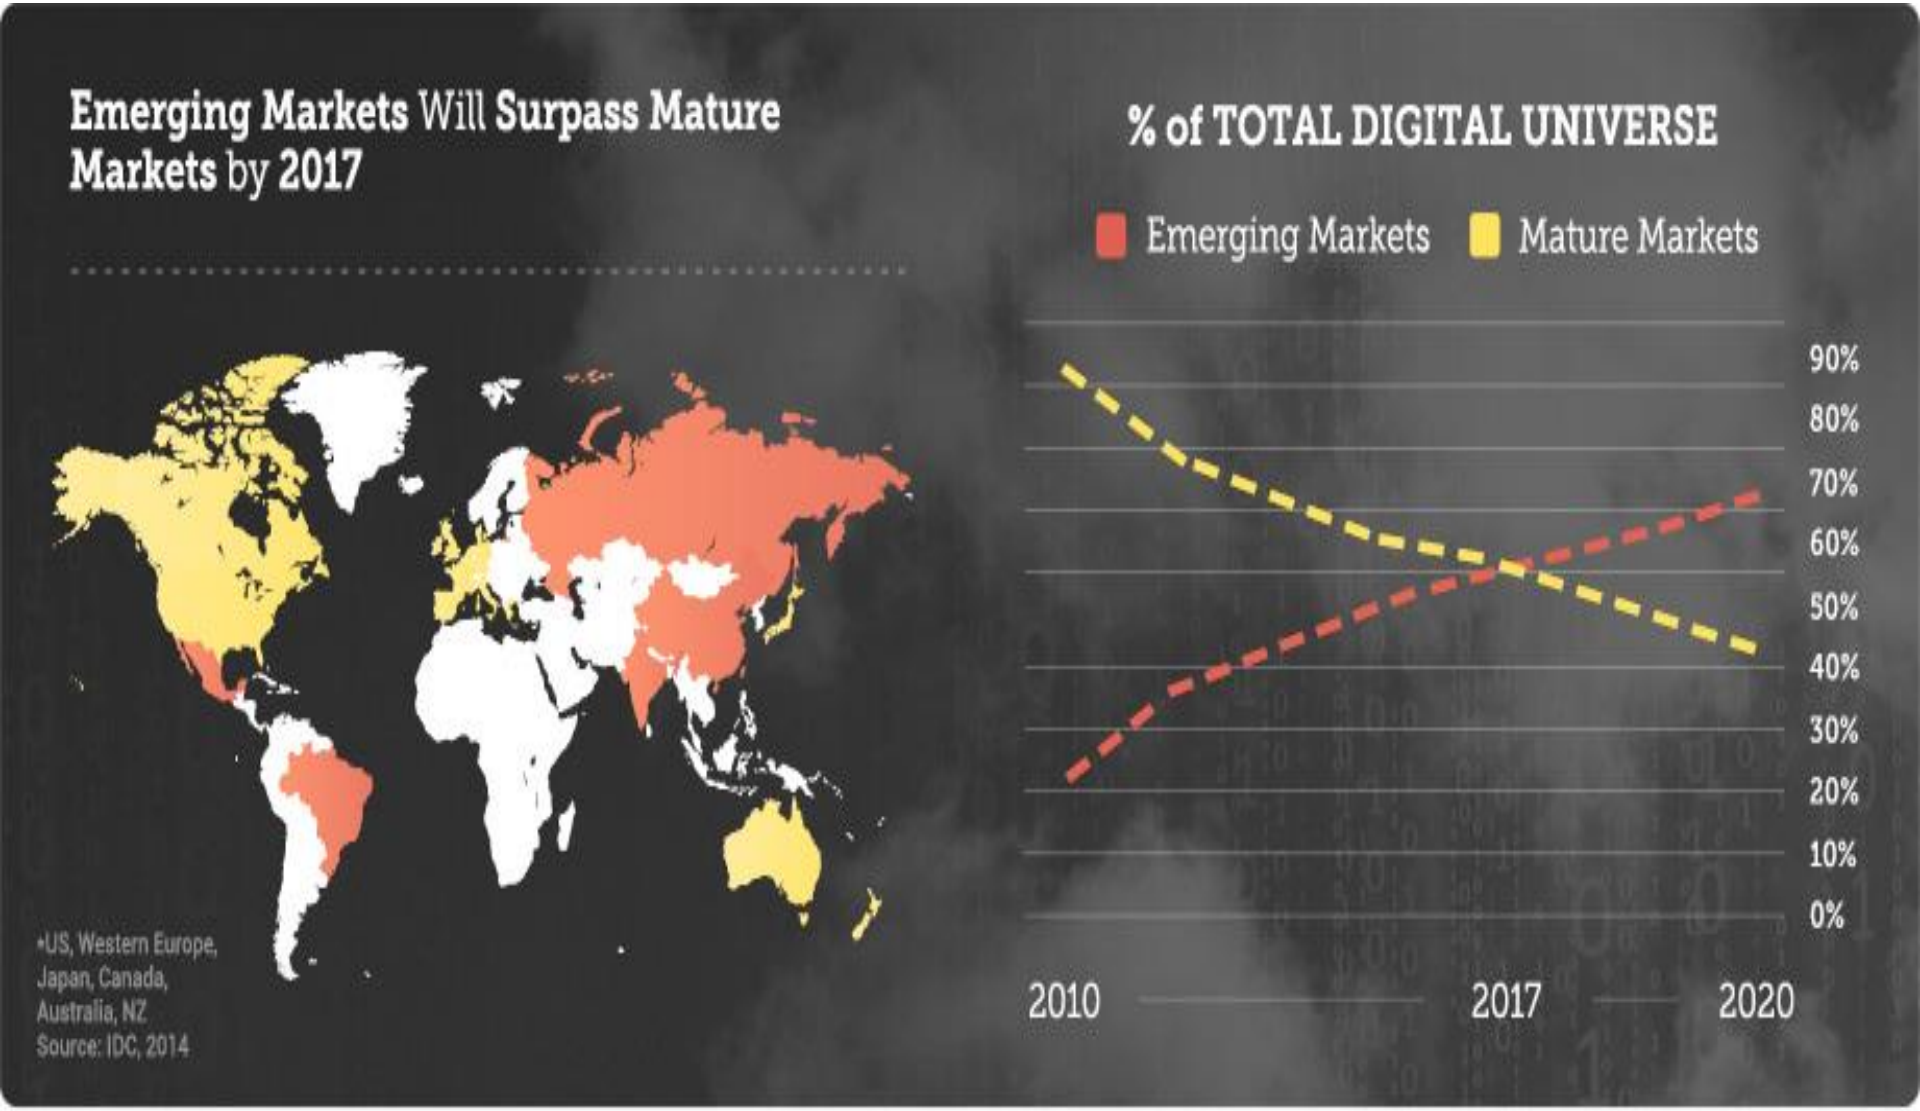


"Data Never Sleeps: AI Edition" by Domo Jul. 2023




Annual Size of the Global Datasphere
175 ZB
Zetabytes
180
160
140
120
100
80
60
40
20
0
2010
2011
2012
2013
2014
2015
2016
2017
2018
2019
2020
2021
2022
2023
2024
2025
Source: Data Age 2025, sponsored by Seagate with data from IDC Global DataSphere, Nov 2018

The Digital Universe (7th EMC Digital Universe study, IDC, 2014)



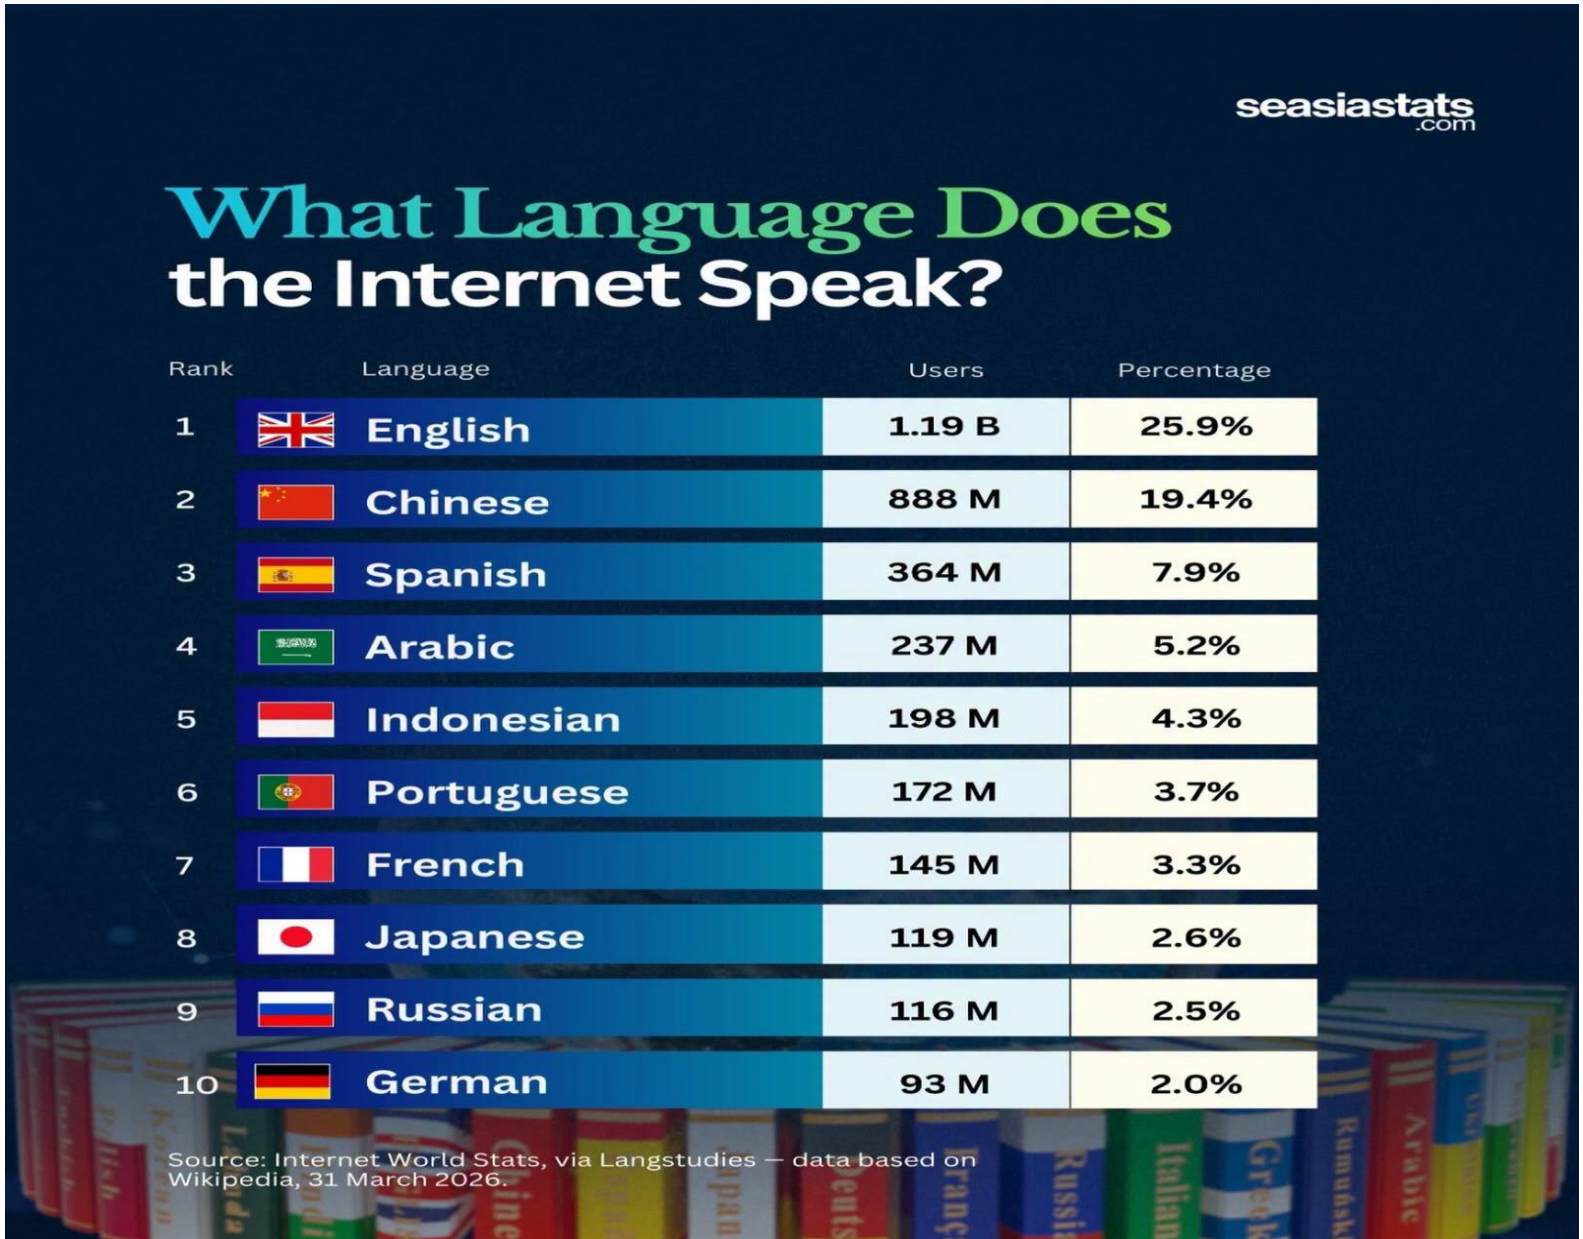
The Digital Universe… The Linguistic Challenge

- Mature markets: USA, Japan, Europe, Canada, Australia, etc.
- Emerging markets: China, Russia, India, Brazil, Mexico, etc.

➔ A multilingual digital universe!

(Chinese, Russian, Hindi, Portuguese, Spanish, etc.)

Top 10 Languages on the Internet in 2026



NLP, a key Solution to the datasphere size and multilingualism !

- Branch of AI at the crossroads of Linguistics, CS, Mathematics, & Statistics.
- **Aim of NLP**: to develop IT tools that can understand and generate natural language so as to make the use of technology seamless / intuitive / natural:
  - Answer semantically richer questions by getting information from the Web and other resources (text, speech)
  - Get help/advice through conversations with the computer / smart phone (virtual assistants, conversational agents)
  - Automatically generate text summaries, articles, books, …
  - Translate documents and speech into different languages
  - Etc.

The Commercial Dimension

Many interesting things in the industry.





THOMSON REUTERS

Google™

YAHOO!®

OpenAI

Microsoft®











Applications

- Let us take a quick look at 3 real-world applications:
  - Automatic Translation (Evolution of Machine Translation)
  - Question answering
  - Text analytics
- And one with an LLM-based conversational agent:
  - ChatGPT

Machine Translation

- Example of English Web page and its online translation to Arabic
  - Go to translate.google.com
  - And type (e.g.) the URL

    https://www.bbc.com/news
  - Translate (for instance) to Arabic
- Impressive evolution during the last 2 decades! (have a look at slides 22 to 28)

Is MT Poor? (example of translation by SYSTRAN in 2005)

Click the Refresh button, or try again later. If you typed the page address in the Address bar, make sure that it is spelled correctly. To check your connection settings, click the Tools menu, and then click Internet Options. On the Connections tab, click Settings. The settings should match those provided by your local area network (LAN) administrator or Internet service provider (ISP). If your Network Administrator has enabled it, Microsoft Windows can examine your network and automatically discover network connection settings. If you would like Windows to try and discover them, click Detect Network Settings Some sites require 128-bit connection security. Click the Help menu and then click About Internet Explorer to determine what strength security you have installed. If you are trying to reach a secure site, make sure your Security settings can support it. Click the Tools menu, and then click Internet Options. On the Advanced tab, scroll to the Security section and check settings for SSL 2.0, SSL 3.0, TLS 1.0, PCT 1.0. Click the Back button to try another link.

Is MT Poor?
(Systran: Eng. to Fr. in 2005)

Cliquetez le bouton de régénération, ou l'essai encore plus tard. Si vous dactylographiiez l'adresse de page dans la barre d'adresse, assurez-vous qu'elle est orthographiée correctement. Pour vérifier

vos arrangements de raccordement, cliquetez le menu d'outils, et puis cliquetez les options d'Internet. Sur l'étiquette de raccordements, cliquetez les arrangements. Les arrangements devraient assortir ceux fournis par votre Internet Service Provider d'administrateur du réseau local (LAN) ou (ISP). Si votre administrateur de réseau l'a permise, Microsoft Windows peut examiner votre réseau et automatiquement découvrir des arrangements de raccordement de réseau. Si vous voudriez que Windows les juge et découvre, le déclic détectent des arrangements de réseau quelques emplacements pour exiger la sécurité du raccordement 128-bit. Cliquetez le menu d'aide et puis cliquetez au sujet de l'Internet Explorer pour déterminer quelle sécurité de force vous avez installée. Si vous essayez d'atteindre un emplacement bloqué, assurez-vous que vos arrangements de sécurité peuvent le soutenir. Cliquetez le menu d'outils, et puis cliquetez les options d'Internet. Sur l'étiquette avançée, faites défiler à la section de sécurité et examinez les arrangements pour assurer SSL 2.0, SSL 3.0, TLS 1.0, PCT 1.0.

Cliquetez le bouton arrière pour essayer un autre lien.

Google Translate 18/09/2017

- Cliquez sur le bouton Actualiser ou essayez à nouveau plus tard. Si vous avez tapé l'adresse de la page dans la barre d'adresse, assurez-vous qu'elle est correctement écrite. Pour vérifier vos paramètres de connexion, cliquez sur le menu Outils, puis sur Options Internet. Dans l'onglet Connexions, cliquez sur Paramètres. Les paramètres doivent correspondre à ceux fournis par votre administrateur de réseau local (LAN) ou fournisseur de services Internet (FAI). Si votre administrateur réseau l'a activé, Microsoft Windows peut examiner votre réseau et découvrir automatiquement les paramètres de connexion réseau. Si vous souhaitez que Windows essaye de les découvrir, cliquez sur Détecter les paramètres réseau. Certains sites nécessitent une sécurité de connexion 128 bits. Cliquez sur le menu Aide, puis cliquez sur À propos d'Internet Explorer pour déterminer la sécurité de sécurité que vous avez installée. Si vous essayez de rejoindre un site sécurisé, assurez-vous que vos paramètres de sécurité peuvent le supporter. Cliquez sur le menu Outils, puis cliquez sur Options Internet. Dans l'onglet Avancé, faites défiler jusqu'à la section Sécurité et vérifiez les paramètres pour SSL 2.0, SSL 3.0, TLS 1.0, PCT 1.0. Cliquez sur le bouton Précédent pour essayer un autre lien.

Google Translate 04/10/2024

Cliquez sur le bouton Actualiser ou réessayez plus tard. Si vous avez saisi l'adresse de la page dans la barre d'adresse, assurez-vous qu'elle est correctement orthographiée. Pour vérifier vos paramètres de connexion, cliquez sur le menu Outils, puis cliquez sur Options Internet. Sous l'onglet Connexions, cliquez sur Paramètres. Les paramètres doivent correspondre à ceux fournis par l'administrateur de votre réseau local (LAN) ou votre fournisseur de services Internet (FAI). Si votre administrateur réseau l'a activé, Microsoft Windows peut examiner votre réseau et découvrir automatiquement les paramètres de connexion réseau. Si vous souhaitez que Windows essaie de les découvrir, cliquez sur Détecter les paramètres réseau. Certains sites nécessitent une sécurité de connexion 128 bits. Cliquez sur le menu Aide, puis cliquez sur À propos d'Internet Explorer pour déterminer le niveau de sécurité que vous avez installé. Si vous essayez d'accéder à un site sécurisé, assurez-vous que vos paramètres de sécurité peuvent le prendre en charge. Cliquez sur le menu Outils, puis cliquez sur Options Internet. Dans l'onglet Avancé, faites défiler jusqu'à la section Sécurité et vérifiez les paramètres pour SSL 2.0, SSL 3.0, TLS 1.0, PCT 1.0. Cliquez sur le bouton Retour pour essayer un autre lien.

Is AMT poor? (translation by a well known AMT software - in 2005)

اضغط الينعش الزّرّ أو يحاول ثانية فيما بعد .إذا طبعت عنوان الصّفحة في بار العنوان, تأكّد أنّه تُتَهَجَّى بطريقة سليمة .لفحص أماكن علاقتك, طقطقة قائمة الأدوات ثمّ طقطقة خيارات الإنترنت . على بطاقة العلاقات, يطقطق الإطارات . ينبغي أن تتلاءم الأماكن هؤلاء إذا بشبكتك المحلّيّة (لان) مدير أو شركة خدمات الإنترنت (آي إس بي) . إذا مسئول شبكتك قد مكّن هو, نوافذ مايكروسوفت يمكن أن تفحص شبكتك و تلقائيًّا تكتشف إطارات توصيل الشّبكة .إذا تريد النّوافذ أن تحاول و تكتشفهم, النّقرة تكتشف أماكن الشّبكة بعض المواقع تتطلّب أمن العلاقة ذو ال128 قطعة . طقطق قائمة المساعدة ثمّ اضغط عن إنترنت إكسبلورار للتحديد ماذا أمن القوّة الذي قد ركّبته . إذا تحاول الوصول إلى موقع آمن, التّأكّد أماكنك الأمنيّة يمكن أن تسانده . طقطق قائمة الأدوات ثمّ طقطق خيارات الإنترنت . على البطاقة المتقدّمة, استعرض إلى القسم الأمنيّ و أوضاع الشّيك لإس إس إل 2.0, إس إس إل 3.0, تي إل إس 1.0, بي سي تي 1.0 . طقطق الزّرّ الخلفيّ لمحاولة رابطة أخرى . لا يمكن أن يجد الخادم أو مستكشف دي إن إس إرورينتيرنيت

Google Translate 18/09/2017

- نقر على الزر تحديث، أو أعد المحاولة لاحقا. إذا قمت بكتابة عنوان الصفحة في شريط العنوان، فتأكد من أنه مكتوب بشكل صحيح. للتحقق من إعدادات الاتصال، انقر فوق القائمة أدوات، ثم انقر فوق خيارات إنترنت. في علامة التبويب اتصالات، انقر فوق إعدادات. يجب أن تتطابق الإعدادات مع تلك التي يوفرها مسؤول الشبكة المحلية (لان) أو موفر خدمة الإنترنت (إيسب). إذا كان مسؤول الشبكة لديك قد مكنها، يمكن ميكروسوفت ويندوز فحص الشبكة الخاصة بك واكتشاف إعدادات اتصال الشبكة تلقائيا. إذا كنت ترغب ويندوز في محاولة واكتشافها، انقر فوق كشف إعدادات الشبكة تتطلب بعض المواقع أمان اتصال 128-بت. انقر فوق القائمة تعليمات ثم انقر فوق حول إنترنيت إكسبلورر لتحديد أمان القوة التي قمت بتثبيتها. إذا كنت تحاول الوصول إلى موقع آمن، فتأكد من أن إعدادات الأمان يمكن أن تدعمه. انقر فوق القائمة أدوات ثم انقر فوق خيارات إنترنت. في علامة التبويب خيارات متقدمة، انتقل إلى قسم الأمان وتحقق من إعدادات سل 2.0 و سل 3.0 و تلس 1.0 و يكت 1.0. انقر فوق الخلف زر لمحاولة ارتباط آخر.

Google Translate 05/10/2024

- انقر على الزر "تحديث"، أو حاول مرة أخرى لاحقًا. إذا قمت بكتابة عنوان الصفحة في شريط العناوين، فتأكد من كتابته بشكل صحيح. للتحقق من إعدادات الاتصال، انقر فوق القائمة "أدوات"، ثم انقر فوق "خيارات الإنترنت". في علامة التبويب اتصالات، انقر فوق الإعدادات. يجب أن تتطابق الإعدادات مع تلك التي يوفرها مسؤول الشبكة المحلية (LAN) أو موفر خدمة الإنترنت .(ISP) إذا قام مسؤول الشبكة لديك بتمكين هذه الميزة، فيمكن لنظام التشغيل Microsoft Windows فحص شبكتك واكتشاف إعدادات اتصال الشبكة تلقائيًا. إذا كنت تريد أن يحاول Windowsاكتشافها، فانقر فوق اكتشاف إعدادات الشبكة. تتطلب بعض المواقع أمان اتصال 128 بت. انقر فوق القائمة "تعليمات" ثم انقر فوق "حول Internet Explorer"لتحديد مدى قوة الأمان التي قمت بتثبيتها. إذا كنت تحاول الوصول إلى موقع آمن، فتأكد من أن إعدادات الأمان لديك تدعم ذلك. انقر فوق القائمة "أدوات"، ثم انقر فوق "خيارات الإنترنت". في علامة التبويب خيارات متقدمة، قم بالتمرير إلى قسم الأمان وتحقق من إعدادات SSL 2.0 و SSL 3.0و TLS 1.0 و PCT 1.0. انقر على زر الرجوع لتجربة رابط آخر .

Web Question-Answering

- What's the population of Timimoun

- ChatGPT (conversational Agent)
  - كيف قام الشعب الجزائري بالثورة

- Answer by ChatGPT (05/10/2024)

- الثورة الجزائرية ضد الاستعمار الفرنسي بدأت في 1 نوفمبر 1954، وكانت نتيجة لعدة عوامل تاريخية وسياسية واقتصادية. إليك بعض النقاط الرئيسية حول كيفية قيام الشعب الجزائري بالثورة:
- **الأسباب التاريخية**: عانت الجزائر من الاستعمار الفرنسي منذ عام 1830، حيث تم استغلال الموارد والثروات، وتم تطبيق سياسات تمييزية ضد الجزائريين.
- **الوعي الوطني**: في بداية القرن العشرين، بدأ الوعي الوطني يزداد بين الجزائريين. نشأت حركات سياسية وثقافية تدعو إلى الاستقلال والحقوق المدنية.
- **العدوان والظلم**: تزايدت الأعمال القمعية ضد الشعب الجزائري، مما أدى إلى استياء واسع النطاق. العديد من الجزائريين كانوا يعيشون في ظروف اقتصادية صعبة وحرمان من الحقوق.
- **التنظيم**: في عام 1954، تأسست جبهة التحرير الوطني ((FLNكحركة سياسية وعسكرية تهدف إلى تحقيق الاستقلال. كانت الجبهة منظمة بشكل جيد ولديها دعم شعبي.
- **اندلاع الثورة**: في ليلة 1 نوفمبر 1954، شن مقاتلو جبهة التحرير الوطني هجمات منسقة على مراكز الشرطة والمكاتب الحكومية، مما أطلق شرارة الثورة.
- **الدعم الدولي**: حظيت الثورة بدعم من العديد من الدول والشعوب الأخرى، وأصبحت قضية الجزائر موضوع اهتمام دولي.
- **الحرب الطويلة**: استمرت الثورة حتى عام 1962، وشهدت مواجهات عسكرية شرسة، مع استخدام الطرف الفرنسي لأساليب قمعية، لكن الجبهة نجحت في الحفاظ على مقاومة مستمرة.
- **الاستقلال**: في عام 1962، تم التوصل إلى اتفاق إيفيان، الذي أدى إلى إعلان استقلال الجزائر في 5 يوليو من نفس العام.
- تُعتبر الثورة الجزائرية واحدة من أبرز الحركات التحررية في القرن العشرين، وقد تركت أثراً عميقاً على الهوية الوطنية الجزائرية.

Text Analytics

- Deriving meaningful insights from unstructured text data.
- Various techniques: NLP, statistical analysis, and machine learning.
- Involves transforming text into a structured format that can be analyzed for patterns, trends, and sentiments.
- Helps organizations to:
  - better understand their customers,
  - identify areas for improvement, and
  - make informed business decisions based on real data.

➔ Ultimately leading to enhanced customer satisfaction and loyalty.

Text Analytics

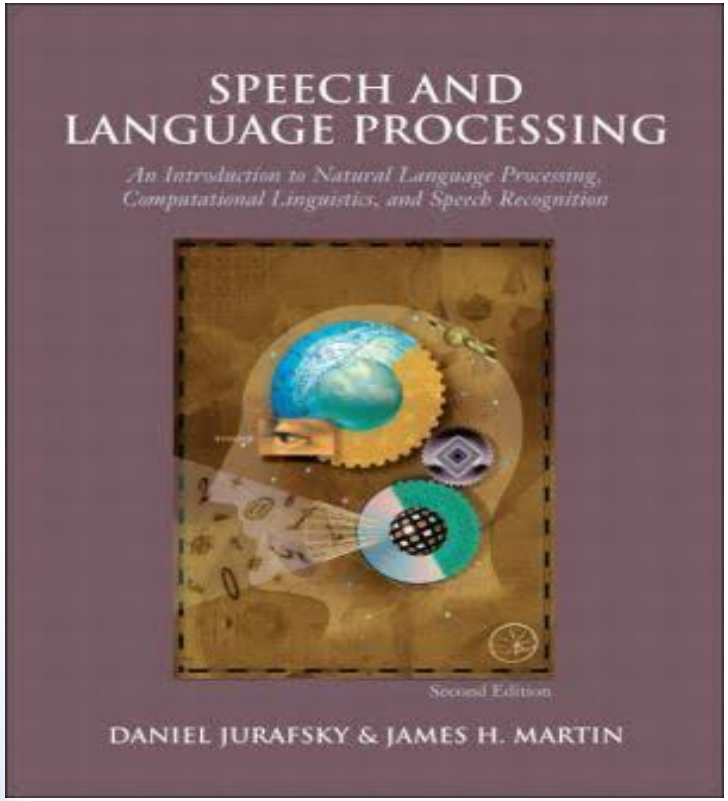
- Information for product marketing
- Data-mining of weblogs, microblogs, discussion forums, message boards, user groups, and other forms of user-generated media (Sentiment Analysis), Social media analytics
- Monitoring political opinions (Opinion mining)
- Tracking the topics of the day (what is "hot", what are the current/discussed topics, etc.)

Chapter References

- Brien Posey, Is your data infrastructure ready for the zettabyte era? TechTarget29/7/2026 https://www.techtarget.com/data-technologies/tip/Is-your-data-infrastructure-ready-for-the-zettabyte-era
- **Data Never Sleeps AI Edition 2025**: https://www.domo.com/learn/infographic/data-never-sleeps-ai-edition-2025
- Edge Delta Team, How Much Data Is Created Per Day? Key Stats and Sources 10/03/2024 https://edgedelta.com/company/knowledge-center/how-much-data-is-created-per-day
- Top 10 Languages on the Internet, https://www.facebook.com/seastats/posts/english-leads-global-internet-users-at-119-billion-or-259-according-to-internet-/1131382285900288/
- Slide 16: https://www.statista.com/statistics/266808/the-most-spoken-languages-worldwide/. Slide 17 calculations based on same reference.
- Slide 34 from Andrew Schwartz, Stony Brook University

Textbook

Jurafsky, D. and Martin, J.H. (2024) *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition with Language Models* (3rd ed. draft), Prentice Hall.
https://web.stanford.edu/~jurafsky/slp3/ed3bookaug20_2024.pdf



The draft version of the 3rd edition will be used; it has been updated to include more recent topics such as Vector Semantics and Embeddings, ANNs and Deep Learning for NLP, Transformers, etc.

This course **slides** are largely based on this textbook and its authors' slides with light customisations whenever seen fit.

This chapter: Slides 8-17 & 21-32 independent researching. (Refs. given)